

HW2 문제 1 배경: 멱법칙 (Power Law) 과 지수분포 (Exponential)

Taek Lim

2026/09/28




Figure 1: 멱법칙의 80/20 을 사람과 양으로 나눠 본 그림, 그리고 정규분포. 읽는 법은 아래 목록.

Figure 1 읽는 법.

(a), (b) 같은 멱법칙 $f(x) = 1.16 x^{-2.16}$, $x_{\min} = 1$.

- 가로축은 로그 눈금이다 (1, 10, 10^2 , ...). 꼬리가 길어 보통 눈금에는 다 들어가지 않는다.
- 두 패널 모두 전체 넓이 = 1 (100%). 넓이가 곧 비율이다.

- 파란 면: $x < 4$. 빨간 면: $x \geq 4$.

(a) **사람의 분포** 넓이 $= \int f(x) dx =$ **사람의 비율**.

- 파란 면: 사람의 80%.
- 빨간 면: 사람의 20%.

(b) **양의 분포** 넓이 $= \int x f(x) dx =$ **양의 비율**.

- 같은 사람들인데 넓이가 뒤집힌다. 파란 면: 양의 20%.
- 빨간 면: 양의 80%. 값 x 를 곱해 큰 x 쪽이 무거워졌다.

(c) **로렌츠 곡선** (a) 와 (b) 를 한 곡선으로 합친 것. 넓이가 아니라 **높이**로 읽는다.

- 가로축: 사람의 누적 비율 (적게 가진 사람부터).
- 세로축: 그 사람들이 가진 양의 누적 비율.
- 파란 실선: (a), (b) 의 먹법칙.
- 주황 일점쇄선: 실제 공항 노선 데이터.
- 회색 점선: 모두가 같은 양을 가질 때 ($y = x$).
- 검은 점 (0.8, 0.2): 하위 80% 가 양의 20% 를 가진다.
- 빨간 굵은 선: 상위 20% 가 양의 80% 를 가진다 (Section 1.3).
- 공항 데이터: 하위 80% 가 양의 16.2% 를 가진다.

(d) **표준정규분포 PDF** 회색 점선, $\mu = 0, \sigma = 1$.

- 평균을 가운데 두고 좌우 대칭이다.
- 평균에서 멀어지면 매우 빨리 0 이 된다.

질문

Suppose the given data points follow a power law distribution: what is power law distribution? and alpha?

1 먹법칙 분포란

강의 노트: 4 장 “분포” §4.4 먹법칙 (04-distributions.tex, deck 6 slide 19–22). 요약 표는 §4.8.

먹법칙 (Power Law) 분포는 소수의 큰 값이 전체의 대부분을 차지하는 분포다. 대부분의 관측값은 작다. 아주 큰 값은 드물지만, 정규분포 (Normal) 나 지수분포 (Exponential) 보다 **훨씬 자주** 나온다. 이 성질을 **꼬리가 두 겹다** (Heavy Tail) 고 한다.

파레토 분포 (Pareto Distribution), “80/20 법칙” 이라고도 부른다. 예: 공항별 노선 수, 도시 인구, 단어 빈도, 부의 분포.

확률밀도함수 (PDF) 는 다음과 같다.

$$f(x) = \frac{\alpha - 1}{x_{\min}} \left(\frac{x}{x_{\min}} \right)^{-\alpha}, \quad x \geq x_{\min}, \alpha > 1 \quad (1)$$

- $x_{\min}$: 먹법칙이 성립하기 시작하는 하한.

- α : 지수 (Power Law Exponent). 꼬리가 얼마나 빨리 줄어드는지 정한다.
- 앞의 $\frac{\alpha-1}{x_{\min}}$ 는 전체 넓이를 1로 맞추는 정규화 상수다.

Figure 2는 $x_{\min} = 1$ 에서 α 만 바꾼 세 곡선이다. 모두 $x_{\min}$ 에서 가장 높고 오른쪽으로 줄어든다.




Figure 2: 멱법칙 PDF $f(x) = (\alpha - 1)x^{-\alpha}$ ($x_{\min} = 1$). 파란 실선 $\alpha = 1.5$, 빨간 점선 $\alpha = 2.5$, 초록 일점쇄선 $\alpha = 3.5$. α 가 클수록 $x_{\min}$ 근처에 몰리고 꼬리가 빨리 줄어든다. α 가 작을수록 꼬리가 두꺼워 $x = 5$ 에서도 높이가 남는다.

1.1 PDF는 어디서 왔나

질문

how did you get pdf for pwer law? is it normal? and why we call pareto distribution? buecauseu 80 normal 20 outlaw? whats its graph look like? can i have a figure at the begiging?

만든 식이 아니라 **멱법칙의 정의**에서 나온다. 멱법칙은 “확률이 x 의 거듭제곱으로 줄어든다”는 가정 하나다.

$$f(x) \propto x^{-\alpha} \quad (\propto: \text{상수배를 빼면 같다})$$

이 가정에 빠진 것은 상수 하나뿐이고, 넓이를 1로 맞추면 정해진다 (Section 2.3). 그 결과가 Equation (1)다. 강의 노트 (deck 6 slide 19–22)와 Clauset et al. (2009)이 쓰는 표준형 (연속형)이 이것이다.

다른 길: 여집합 CDF에서 미분. 파레토는 “ x 보다 큰 값의 비율”로 정의했다. 여기서 시작해도 같은 식이 나온다.

$$\begin{aligned} P(X \geq x) &= \left(\frac{x}{x_{\min}} \right)^{-(\alpha-1)} && x \text{보다 큰 비율 (Section 2.1.1의 기울기 } -(\alpha-1)) \\ f(x) &= -\frac{d}{dx} P(X \geq x) && \text{PDF는 CDF의 기울기} \\ &= (\alpha-1) \left(\frac{x}{x_{\min}} \right)^{-\alpha} \cdot \frac{1}{x_{\min}} && \text{거듭제곱 미분, 지수가 1 줄었다} \end{aligned}$$

Equation (1)와 같다.

1.2 정규분포인가

아니다. 정규분포 (Normal) 와 모양이 정반대에 가깝다 (Figure 1).

Table 1: 멱법칙과 정규분포 비교

	멱법칙 (Power Law)	정규분포 (Normal)
가장 높은 곳	$x_{\min}$ (맨 왼쪽)	평균 μ (가운데)
모양	한쪽으로만 줄어듦	좌우 대칭 종 모양
값의 범위	$x \geq x_{\min} > 0$	모든 실수
꼬리	$x^{-\alpha}$, 느리게 줄어듦	$e^{-x^2/2}$, 매우 빨리 줄어듦
평균이 대표값인가	아니다 (소수가 끌어올림)	그렇다 (평균 = 중앙값)

예제: 공항 노선 수. 평균과 중앙값이 크게 다르다.

$$\bar{x} = 19.8$$

$$\text{중앙값} = 4$$

$$82\%$$

평균

절반의 공항은 노선 4 개 이하

평균보다 작은 공항의 비율

정규분포라면 평균 아래가 절반 (50%) 이어야 한다.

1.3 왜 파레토 분포라고 부르나

이탈리아 경제학자 빌프레도 파레토 (Vilfredo Pareto) 의 이름이다. 그는 1890 년대에 소득이 x 이상인 사람의 수가 x 의 거듭제곱으로 줄어든다는 것을 관찰했다. 흔히 전하는 예가 “이탈리아 땅의 80% 를 인구 20% 가 가진다” 이다. “80/20 법칙” (Pareto Principle) 이라는 이름은 뒤에 품질 관리 분야의 조셉 주란 (Joseph Juran) 이 붙였다.

“80 정상, 20 이상치” 가 아니다. 80/20 은 **사람의 20% 가 전체 양의 80% 를 가진다**는 뜻이다. 20% 는 버릴 이상치가 아니라 분포의 핵심인 긴 꼬리다 (Figure 1(a), (b) 의 빨간 면).

질문

가진 양이 그래프 아래면적을 이야기 하는거야? 그런데 그림 상으로 80 퍼센트 사람이 가진 양이 20 퍼센트로 안 보여 스케일 다르게 해서 보여줘야 하는 거아니야?

PDF 아래 넓이는 사람의 비율이지 양이 아니다. 두 넓이를 구별해야 한다.

$$\int_a^b f(x) dx$$

a 와 b 사이에 있는 **사람의 비율**

$$\int_a^b x f(x) dx$$

그 사람들이 가진 **양** (값 x 를 곱했다)

Figure 1(a) 의 넓이는 첫째 줄, (b) 의 넓이는 둘째 줄이다. 그래서 파란 면이 커 보이는 것이 맞다. 사람은 80% 가 거기 있다. 양은 둘째 줄인데, 큰 x 가 곱해지므로 꼬리 쪽 무게가 커진다. 그 양의 대부분은 그림 오른쪽 끝

($x = 10$) 너머 먼 꼬리에 있다.

$$\int_4^{10} x f(x) dx / E[X] = 0.11$$

$$0.80 - 0.11 = 0.69$$

그림에 보이는 빨간 구간의 양

$x > 10$ 에 있는 양

보통 눈금으로는 꼬리가 잘린다. 그래서 Figure 1 는 가로축을 로그 눈금으로 바꾸고, (a) 사람과 (b) 양을 같은 축에 나란히 그렸다. 두 비율을 한 곡선으로 합치면 (c) 의 **로렌츠 곡선** (Lorenz Curve) 이 된다. 넓이가 아니라 **높이**로 읽는다. 가로 0.8 에서 곡선 높이가 0.2 면 하위 80% 가 20% 를 가진 것이다.

80/20 은 α 하나에서만 정확하다. 상위 비율 p 가 가진 양의 몫은 $\alpha > 2$ 일 때 다음과 같다.

$$\text{몫} = p^{(\alpha-2)/(\alpha-1)} \quad (x \cdot f(x) \text{ 를 꼬리에서 적분해 평균으로 나눈 값})$$

$$\alpha = 2.16, p = 0.2$$

가정

$$(2.16 - 2)/(2.16 - 1) = 0.138$$

지수

$$0.2^{0.138} = 0.80$$

상위 20% 가 80% 를 가진다

α 가 2 에 가까워지면 몫은 1(100%) 로 가고, α 가 커지면 줄어든다. 그래서 “80/20” 은 멱법칙의 한 예일 뿐 모든 멱법칙의 성질은 아니다.

예제: 공항 데이터. 노선이 많은 순으로 상위 20% 를 센다.

$$3409 \times 0.2 = 682$$

상위 20% 공항 수

$$83.8\%$$

그 682 곳이 가진 노선의 몫

실제 데이터가 거의 80/20 이다. 적합한 $\hat{\alpha} = 1.612 < 2$ (Section 4) 로는 몫이 100% 에 가까워야 하는데, 실제 데이터는 큰 값에서 끊기기 (Cutoff) 때문에 83.8% 에서 멈춘다.

2 PDF 식의 각 조각은 왜 있나

$$f(x) = \frac{\alpha - 1}{x_{\min}} \left(\frac{x}{x_{\min}} \right)^{-\alpha}, \quad x \geq x_{\min}, \quad \alpha > 1$$

결론. 분포의 모양을 정하는 것은 $x^{-\alpha}$ 하나뿐이다. 나머지 ($x \geq x_{\min}, \alpha > 1$, 앞의 상수 $\frac{\alpha-1}{x_{\min}}$) 는 이 모양을 **올 바른 확률분포** (넓이가 유한하고 정확히 1) 로 만드는 장치다.

Table 2: 식의 각 조각과 그것이 막는 문제.

조각	하는 일	없으면 생기는 문제
$x^{-\alpha}$	천천히 줄어드는 꼬리 (heavy tail)	큰 값이 너무 드물게 나온다
$x \geq x_{\min}$	0 근처를 잘라 낸다	$x \rightarrow 0$ 에서 넓이가 무한대
$\alpha > 1$	꼬리 넓이를 유한하게	$x \rightarrow \infty$ 에서 넓이가 무한대
$\frac{\alpha-1}{x_{\min}}$	전체 넓이를 1 로	확률의 합이 1 이 아니다
$\frac{x}{x_{\min}}$	“최솟값의 몇 배인가” 로 읽기	(표기상 편의, 단위가 사라짐)

2.1 핵심 모양: $x^{-\alpha}$

고치는 문제. 부 (wealth), 도시 인구, 웹페이지 링크 수, 단어 빈도 같은 데이터에는 작은 값이 매우 많고, 아주 큰 값도 드물지만 무시할 수 없을 만큼 나온다. 정규분포 (Normal) 나 지수분포 (Exponential) 는 큰 값의 확률을 너무 빨리 0 으로 떨어뜨려 이런 데이터를 설명하지 못한다.

아이디어. 지수 e^{-x} 대신 거듭제곱 $x^{-\alpha}$ 로 줄어들게 한다. Table 3 이 그 차이를 숫자로 보여 준다.

Table 3: 같은 x 에서 지수분포와 멱법칙의 밀도 비교 ($\alpha = 2$).

x	지수 e^{-x}	멱법칙 x^{-2}
1	0.37	1
10	0.000045	0.01
100	3.7×10^{-44}	0.0001

$x = 100$ 에서 지수분포는 사실상 0 이지만 멱법칙은 여전히 1 만 분의 1 이다. 이것을 **두꺼운 꼬리** (heavy tail) 라고 부른다. Figure 3 은 같은 차이를 세로축 로그 눈금으로 그린 것이다.




Figure 3: 멱법칙 (파란 실선, $\alpha = 2$, $x_{\min} = 1$) 과 지수분포 (주황 점선, 비율 1, $x_{\min} = 1$ 에서 시작) 의 밀도. 세로축은 로그 눈금이다. $x = 10$ 에서 멱법칙은 10^{-2} , 지수분포는 약 $10^{-3.9}$ 로 약 80 배 차이 난다.

척도 불변 (scale-free). x 를 두 배로 늘리면 밀도는 x 가 얼마이든 늘 같은 비율로 줄어든다.

$$\frac{f(2x)}{f(x)} = \frac{(2x)^{-\alpha}}{x^{-\alpha}} = 2^{-\alpha} \quad (x \text{ 가 식에서 사라진다})$$

“1 만 원에서 2 만 원” 과 “1 억에서 2 억” 이 같은 비율로 줄어든다는 뜻이다. 지수분포는 $\frac{e^{-2x}}{e^{-x}} = e^{-x}$ 로 x 에 따라 달라지므로 이 성질이 없다.

α 와 꼬리의 두께. α 가 작을수록 꼬리가 두꺼워 극단값이 더 자주 나온다. α 가 클수록 꼬리가 빨리 줄어든다.

2.1.1 로그-로그 축에서 직선

Equation (1) 의 양변에 로그를 취한다.

$$\begin{aligned} f(x) &= C x^{-\alpha} && \text{상수를 } C \text{ 로 묶었다} \\ \log f(x) &= \log C - \alpha \log x && \text{양변에 로그} \end{aligned}$$

$\log x$ 에 대해 일차식이다. 그래서 **로그-로그 축에서 기울기가 $-\alpha$ 인 직선**이 된다. 지수분포는 같은 축에서 아래로 휘는 곡선이다 (Figure 4). 이것으로 둘을 구별한다.

여집합 CDF $P(X \geq x)$ 로 그리면 기울기는 $-(\alpha - 1)$ 이다. 적분하면서 지수가 하나 줄기 때문이다.




Figure 4: 로그-로그 축에서 멱법칙 (파란 실선) 과 지수분포 (빨간 점선). 멱법칙은 기울기 $-\alpha$ 의 직선, 지수분포는 아래로 휘는 곡선이다.

질문

2.1.1: explain why 지수 분포는 아래로 휘는지?

답: 기울기가 x 에 비례해 커지기 때문이다. 직선이란 기울기가 어디서나 같은 선이다. 그러니 로그-로그 축에서 두 분포의 **기울기**를 구해 비교하면 된다. 가로축을 $u = \ln x$ 로 둔다. 곧 $x = e^u$ 다.

멱법칙은 기울기가 상수다.

$$\begin{aligned} \ln f &= \ln C - \alpha \ln x = \ln C - \alpha u && u \text{ 에 대해 일차식} \\ \frac{d \ln f}{du} &= -\alpha && \text{기울기: } x \text{ 와 상관없이 일정} \end{aligned}$$

지수분포 $f(x) = \lambda e^{-\lambda x}$ 는 다르다.

$$\begin{aligned} \ln f &= \ln \lambda - \lambda x \\ &= \ln \lambda - \lambda e^u && \text{양변에 로그} \\ &&& x = e^u \text{ 를 대입: } u \text{ 에 대해 일차식이 아니다} \\ \frac{d \ln f}{du} &= -\lambda e^u = -\lambda x && \text{기울기가 } -\lambda x \end{aligned}$$

기울기가 $-\lambda x$ 이므로 x 가 커질수록 기울기가 점점 더 가팔라진다. 오른쪽으로 갈수록 더 빨리 떨어지는 선, 곧 **아래로 휘는 곡선**이다. 로그의 밑을 10 으로 바꿔도 가로와 세로가 같은 비율 ($\ln 10$) 로 줄어 기울기는 같다.

직관. 로그 축에서 한 칸은 “10 배” 다. $1 \rightarrow 10$ 도 한 칸, $10 \rightarrow 100$ 도 한 칸이다. 멱법칙은 x 가 10 배가 될 때마다 f 가 늘 같은 비율 $10^{-\alpha}$ 로 줄어서 칸마다 같은 높이만큼 내려간다. 지수분포는 x 가 **더해진 양**만큼 줄어든다. $1 \rightarrow 10$ 은 9 를 더한 것이고, $10 \rightarrow 100$ 은 90 을 더한 것이다. 같은 한 칸인데 뒤의 칸에서 10 배 더 많이 떨어진다.

예제. Figure 4 의 두 곡선 ($C = 1$, $\alpha = 2.5$ 멱법칙과 $\lambda = 1$ 지수분포 e^{-x}) 의 높이와 기울기를 몇 점에서 계산했다 (Table 4). 지수분포의 높이는 $\log_{10} e^{-x} = -0.4343 x$ 다.

Table 4: 로그-로그 축에서 높이 $\log_{10} f(x)$ 와 기울기. 멱법칙 ($\alpha = 2.5$) 은 기울기가 -2.5 로 일정하고, 지수분포 (e^{-x}) 는 기울기 $-x$ 가 점점 가팔라진다.

x	$\log_{10} x$	멱법칙 높이	멱법칙 기울기	지수 높이	지수 기울기
1	0	0	-2.5	-0.43	-1
2	0.301	-0.75	-2.5	-0.87	-2
5	0.699	-1.75	-2.5	-2.17	-5
10	1	-2.5	-2.5	-4.34	-10

$x = 1$ 에서는 지수분포가 오히려 완만하다 (기울기 -1 대 -2.5). $x = 10$ 에서는 4 배 더 가파르다 (기울기 -10). 그래서 지수분포의 꼬리는 결국 멱법칙보다 훨씬 빨리 사라진다 (Figure 3 과 같은 이야기).

2.2 왜 $x \geq x_{\min}$ 인가

$x^{-\alpha}$ 는 $x \rightarrow 0$ 에서 무한대로 커진다. $\alpha > 1$ 이면 0 근처의 넓이도 무한대다.

$$\int_0^1 x^{-\alpha} dx = \left[\frac{x^{1-\alpha}}{1-\alpha} \right]_0^1 = \infty \quad (1-\alpha < 0 \text{ 이므로 } x \rightarrow 0 \text{ 에서 } x^{1-\alpha} \rightarrow \infty)$$

그래서 하한 $x_{\min} > 0$ 을 두고, 그 위에서만 멱법칙이 성립한다고 본다. 실제 데이터도 대개 어떤 값 이상의 꼬리에서만 멱법칙을 따른다.

2.3 정규화 상수와 $\alpha > 1$: 곡선 아래 넓이 = 1

질문

앞의 $\frac{\alpha-1}{x_{\min}}$ 는 전체 넓이를 1 로 맞추는 정규화 상수다. » area below distribution line => 1?

그렇다. PDF 곡선 아래 전체 넓이는 “어떤 값이든 하나는 나올 확률” 이므로 반드시 1 이다.

$$\int_{x_{\min}}^{\infty} f(x) dx = 1 \quad (\text{모든 PDF 의 조건})$$

$x^{-\alpha}$ 만으로는 넓이가 1 이 아니다. 그래서 앞에 상수 C 를 곱해 넓이를 1 로 맞춘다. 이 C 가 **정규화 상수** (Normalization Constant) 다.

C 구하기. $x^{-\alpha}$ 의 넓이를 먼저 구한다.

$$\begin{aligned}\int_{x_{\min}}^{\infty} x^{-\alpha} dx &= \left[\frac{x^{1-\alpha}}{1-\alpha} \right]_{x_{\min}}^{\infty} \\ &= 0 - \frac{x_{\min}^{1-\alpha}}{1-\alpha} \\ &= \frac{x_{\min}^{1-\alpha}}{\alpha-1}\end{aligned}$$

거듭제곱 적분

$\alpha > 1$ 이면 $x \rightarrow \infty$ 에서 $x^{1-\alpha} \rightarrow 0$

부호 정리

넓이가 1 이 되려면 C 는 이 값의 역수다.

$$\begin{aligned}C &= (\alpha-1) x_{\min}^{\alpha-1} \\ f(x) &= (\alpha-1) x_{\min}^{\alpha-1} x^{-\alpha} \\ &= \frac{\alpha-1}{x_{\min}} \cdot x_{\min}^{\alpha} x^{-\alpha} \\ &= \frac{\alpha-1}{x_{\min}} \left(\frac{x}{x_{\min}} \right)^{-\alpha}\end{aligned}$$

넓이의 역수

$f(x) = C x^{-\alpha}$ 에 C 를 대입

$$x_{\min}^{\alpha-1} = x_{\min}^{\alpha} / x_{\min}$$

$$x_{\min}^{\alpha} x^{-\alpha} = (x/x_{\min})^{-\alpha}$$

Equation (1) 와 같다. 둘째 줄에서 $\alpha > 1$ 이 쓰였다. $\alpha \leq 1$ 이면 넓이가 무한대라 어떤 C 로도 1 을 만들 수 없다. 이것이 $\alpha > 1$ 조건의 이유다. 마지막 형태로 쓰는 이유는 읽기 쉬워서다. $\frac{x}{x_{\min}}$ 은 “최솟값의 몇 배인가” 이고 단위 (원, 명) 가 사라진다.

예제. $\alpha = 2.5$, $x_{\min} = 1$.

$$\int_1^{\infty} x^{-2.5} dx = \frac{1}{1.5} = 0.667$$

$$C = 1.5$$

$$1.5 \times 0.667 = 1$$

상수 없이 넓이

역수

곱하면 넓이 1




Figure 5: $\alpha = 2.5$, $x_{\min} = 1$ 의 멱법칙 PDF $f(x) = 1.5 x^{-2.5}$ (빨간 점선). 빨간 면이 곡선 아래 넓이다. $x = 5$ 너머 꼬리까지 합치면 정확히 1 이다.

2.4 작은 예제: $\alpha = 2$, $x_{\min} = 1$

$$f(x) = \frac{2-1}{1} \left(\frac{x}{1} \right)^{-2} = \frac{1}{x^2}$$

x 이상일 확률 (꼬리 확률) 은 f 를 x 부터 적분해서 얻는다.

$$P(X \geq x) = \int_x^\infty \frac{1}{t^2} dt = \frac{1}{x} \quad (\text{일반형: } (x/x_{\min})^{-(\alpha-1)})$$

Table 5: $\alpha = 2$, $x_{\min} = 1$ 일 때 밀도와 꼬리 확률.

x	$f(x) = 1/x^2$	$P(X \geq x) = 1/x$
1	1	1 (전부)
2	0.25	0.5
10	0.01	0.1
100	0.0001	0.01

100 명 중 1 명은 최솟값의 100 배를 넘는다. 지수분포였다면 사실상 한 명도 없다 (Table 3).

2.5 α 가 평균과 분산을 결정한다

강의 노트: §4.4 먹법칙 (로그-로그 그림, deck 6 slide 22). 평균과 분산의 조건은 §4.8 요약 표의 “조건부 존재” 칸.

- $\alpha > 1$: 넓이가 1 이 되려면 (확률분포가 되려면) 필요하다.
- $\alpha > 2$: 이때만 평균이 유한하다. $E[X] = \frac{\alpha-1}{\alpha-2} x_{\min}$.
- $\alpha > 3$: 이때만 분산이 유한하다.

실제 데이터는 흔히 $2 < \alpha < 3$ 이다. 평균은 있어도 분산이 발산하는 경우가 많다.

질문

2.2 α 에 걸린 조건 (위 세 줄): explain more on this

2.5.1 핵심 도구: x^{-p} 의 넓이는 언제 유한한가

세 조건은 모두 한 가지 사실에서 나온다.

$$\int_1^\infty x^{-p} dx = \begin{cases} \frac{1}{p-1} & p > 1 \quad (\text{유한}) \\ \infty & p \leq 1 \quad (\text{발산}) \end{cases}$$

곡선이 x^{-p} 로 줄어듦 때, p 가 1 보다 커야 꼬리가 충분히 빨리 줄어 넓이가 유한하다. $p = 1$ 이 경계다.

$$\begin{aligned} \int_1^{1000} x^{-1} dx &= \ln 1000 = 6.9 & p = 1: \text{구간을 늘리면} \\ \int_1^{10^6} x^{-1} dx &= \ln 10^6 = 13.8 & \text{넓이가 끝없이 커진다} \\ \int_1^\infty x^{-2} dx &= 1 & p = 2: \text{유한} \end{aligned}$$

2.5.2 평균과 분산은 넓이 계산이다

평균과 분산도 적분이다. 적분 안에 x 를 한 번, 두 번 더 곱할 뿐이다.

$$E[X] = \int_{x_{\min}}^{\infty} x \cdot Cx^{-\alpha} dx = C \int_{x_{\min}}^{\infty} x^{-(\alpha-1)} dx \quad x \text{ 를 한 번 곱했다: } p = \alpha - 1$$

$$E[X^2] = \int_{x_{\min}}^{\infty} x^2 \cdot Cx^{-\alpha} dx = C \int_{x_{\min}}^{\infty} x^{-(\alpha-2)} dx \quad \text{두 번 곱했다: } p = \alpha - 2$$

x 를 곱할 때마다 지수 p 가 1 씩 줄어 꼬리가 느려진다. 각각에 “ $p > 1$ ” 을 쓴다.

Table 6: x^k 를 곱한 적분이 유한해지는 조건. k 는 곱한 횟수.

구하는 것	적분 안의 꼬리	유한 조건 $p > 1$	결론
전체 넓이 ($k = 0$)	$x^{-\alpha}$	$\alpha > 1$	확률분포가 된다
평균 $E[X]$ ($k = 1$)	$x^{-(\alpha-1)}$	$\alpha - 1 > 1$	$\alpha > 2$
$E[X^2]$ ($k = 2$)	$x^{-(\alpha-2)}$	$\alpha - 2 > 1$	$\alpha > 3$

분산은 $\text{Var}[X] = E[X^2] - (E[X])^2$ 이므로 $E[X^2]$ 가 유한해야 유한하다. 그래서 분산의 조건은 $\alpha > 3$ 이다.

2.5.3 유한할 때의 값

$C = (\alpha - 1) x_{\min}^{\alpha-1}$ (Section 2.3) 를 넣고 적분하면 다음과 같다.

$$E[X] = \frac{\alpha - 1}{\alpha - 2} x_{\min} \quad \alpha > 2$$

$$E[X^2] = \frac{\alpha - 1}{\alpha - 3} x_{\min}^2 \quad \alpha > 3$$

$$\text{Var}[X] = \frac{\alpha - 1}{(\alpha - 2)^2(\alpha - 3)} x_{\min}^2 \quad \alpha > 3$$

분모의 $\alpha - 2$, $\alpha - 3$ 이 0 에 가까워지면 값이 무한대로 커진다. 식 모양에도 조건이 드러난다.

예제 1: $\alpha = 4$, $x_{\min} = 1$ (셋 다 유한).

$E[X] = 3/2 = 1.5$	평균
$E[X^2] = 3/1 = 3$	제곱의 평균
$\text{Var}[X] = 3 - 1.5^2 = 0.75$	분산 (공식으로도 $3/(4 \cdot 1) = 0.75$)

예제 2: $\alpha = 2.5$, $x_{\min} = 1$ (평균만 유한).

$E[X] = 1.5/0.5 = 3$	평균은 유한
$\alpha - 2 = 0.5 \leq 1$	$E[X^2]$ 의 꼬리 $x^{-0.5}$: 발산, 분산은 무한

2.5.4 데이터 분석에서 뜻하는 것

“평균이 무한”은 실제 데이터의 평균이 무한대라는 뜻이 아니다. 유한한 표본의 평균은 언제나 숫자 하나로 계산 된다. 뜻하는 것은 **표본 평균이 한 값으로 수렴하지 않는다**는 것이다. 표본을 늘릴수록 전보다 더 큰 극단값이 들어와 표본 평균이 계속 쏠린다.

- $\alpha > 3$: 평균, 분산 모두 안정. 표본을 늘리면 정해진 값에 다가간다.
- $2 < \alpha \leq 3$: 표본 평균은 수렴하지만, 표본 분산 (표준편차) 은 표본이 커질수록 계속 커진다. 평균 $\pm$ 표준편차 같은 요약이 믿을 만하지 않다.
- $1 < \alpha \leq 2$: 표본 평균조차 수렴하지 않는다. 평균보다 중앙값 (Median) 이 나은 요약이다.

문제 1(a)의 공항 데이터는 $\hat{\alpha} = 1.612$ 로 마지막 경우다 (Section 4).

α 가 작을수록 꼬리가 두껍고, “상위 소수가 전체 양의 대부분을 가진다”(80/20)는 현상이 강해진다. 이 부분은 Figure 1의 사람 대 양 그림과 이어진다.

3 데이터에서 α 추정하기

강의 노트: 10장 “과제 2” §10.2 모수 추정 (hw02-data-distributions.tex, 역법칙 MLE 예제).

최대우도추정 (MLE, Maximum Likelihood Estimation; Clauset et al. 2009)을 쓴다.

$$\hat{\alpha} = 1 + \frac{n}{\sum_{i=1}^n \ln(x_i/x_{\min})} \quad (2)$$

HW2 코드 (hw2/code/p1.py의 fit_power_law)도 이 식을 쓰고, $x_{\min}$ 은 데이터의 최솟값으로 둔다.

로그-로그 히스토그램에 직선을 그어 기울기를 읽는 방법은 편향이 커서 권장하지 않는다. 직선이 맞는지 눈으로 확인하는 용도로만 쓴다.

예제. 데이터 $\{1, 2, 4, 8\}$, $x_{\min} = 1$, $n = 4$.

$$\ln(1/1) = 0$$

$$\ln(2/1) = 0.693$$

$$\ln(4/1) = 1.386$$

$$\ln(8/1) = 2.079$$

$$0 + 0.693 + 1.386 + 2.079 = 4.159$$

$$1 + 4/4.159 = 1.962$$

분모 (로그의 합)

$\hat{\alpha}$

$\hat{\alpha} \approx 1.96 < 2$ 이므로, 이 모형에서는 평균이 유한하지 않다.

4 HW2 문제 1(a): 공항 노선 수 데이터

강의 노트: §10.4 공항 노선 수, §10.3 네 모형을 비교하는 방법. KS 거리는 8장 §8.8, Q-Q 플롯은 5장 §5.5.

문제 1(a)

What is the α if the distribution is power law?

Equation (2) 를 공항별 노선 수 데이터 (01_airport_routes.csv) 에 적용한다. 보고서의 답은 다음과 같다.

$$\begin{aligned} n &= 3409 \\ x_{\min} &= 1 \\ \hat{\alpha} &= 1.612 \end{aligned}$$

공항 수
데이터의 최솟값 (노선 1 개)
Equation (2) 의 결과

4.1 $\hat{\alpha} = 1.612$ 가 뜻하는 것

$1 < \hat{\alpha} < 2$ 이다. Section 2.5 의 조건에 따라 확률분포는 되지만, 이 모형에서는 평균도 분산도 유한하지 않다. 그래서 모형에서 뽑은 표본은 노선이 10^4 에서 10^5 개인 공항까지 만들어 낸다. 실제 데이터는 최대 915 에서 멈춘다.

4.2 적합이 맞는 범위

- 노선 1 개에서 약 60 개까지: 여집합 CDF 가 데이터와 겹치고, QQ 점이 $y = x$ 위에 놓인다.
- 약 100 개 이상: 데이터는 아래로 휘며 끊기고 (Cutoff), 모형은 직선으로 계속 간다.
- KS 거리 (Kolmogorov–Smirnov Distance) $D = 0.209$ 로 네 모형 (멱법칙, 지수, 균등, 정규) 중 가장 작다.




Figure 6: 공항 노선 수에 멱법칙 ($\hat{\alpha} = 1.612$, $x_{\min} = 1$) 을 적합한 결과 (code/p1.py 가 생성). $D = 0.209$.

5 지수분포란

강의 노트: 4 장 §4.3 지수분포 (deck 6 slide 15–18). CDF 의 정의는 2 장 §2.4.

질문

p1-b what is exponential distribution? why we need lambda? and what it is? why important?

지수분포 (Exponential Distribution) 는 다음 사건까지 기다리는 시간을 나타내는 분포다. 예: 다음 손님이 올 때까지의 시간, 다음 고장까지의 시간. 작은 값이 가장 흔하고, 값이 커질수록 확률이 일정한 비율로 줄어든다.

확률밀도함수 (PDF) 와 여집합 CDF 는 다음과 같다.

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0, \lambda > 0 \quad (3)$$

$$P(X > x) = e^{-\lambda x} \quad (4)$$

Figure 7 는 λ 만 바꾼 세 곡선이다. 모두 $x = 0$ 에서 높이 λ 로 시작해 줄어든다.




Figure 7: 지수분포 PDF $f(x) = \lambda e^{-\lambda x}$. 파란 실선 $\lambda = 0.5$, 빨간 점선 $\lambda = 1$, 초록 일점쇄선 $\lambda = 2$. 모양은 셋 다 같고 눈금만 다르다. λ 가 클수록 0 근처에 몰리고 평균 $1/\lambda$ 가 작아진다.

5.1 λ 는 무엇인가

λ 는 **비율** (Rate) 이다. 단위 시간당 사건이 평균 몇 번 일어나는지를 뜻한다.

$E[X] = 1/\lambda$	평균 대기 시간
$SD[X] = 1/\lambda$	표준편차도 평균과 같다

예: 손님이 분당 평균 $\lambda = 0.5$ 명 온다면, 평균 대기 시간은 $1/0.5 = 2$ 분이다.

5.2 왜 λ 가 필요한가

지수분포의 **모양**은 하나로 정해져 있다 (0 에서 가장 높고, 오른쪽으로 줄어드는 곡선). 정해지지 않은 것은 **눈금** (Scale) 뿐이다. 곡선이 몇 분 만에 줄어드는지, 몇 시간에 걸쳐 줄어드는지를 λ 하나가 정한다. 그래서 λ 없이는 어떤 확률도 숫자로 계산할 수 없다.

예: $\lambda = 0.5$ 일 때 4 분 넘게 기다릴 확률은 Equation (4) 로

$$P(X > 4) = e^{-0.5 \cdot 4} = e^{-2} = 0.135 \quad (\text{약 } 13.5\%)$$

5.3 데이터에서 λ 추정하기

최대우도추정 (MLE) 은 표본 평균의 역수다.

$$\hat{\lambda} = \frac{1}{\bar{x}} \quad (\text{평균이 } 1/\lambda \text{ 이므로 거꾸로 푼다})$$

5.4 왜 중요한가

- **무기억성** (Memoryless Property): 이미 s 만큼 기다렸어도, 앞으로 t 더 기다릴 확률은 처음과 같다. $P(X > s + t \mid X > s) = e^{-\lambda t} = P(X > t)$. 연속 분포 중 이 성질을 가진 것은 지수분포뿐이다.
- 포아송 과정 (Poisson Process) 과 짝이다. 일정 시간 동안 사건 수가 포아송분포를 따르면, 사건 사이 간격은 지수분포를 따른다.
- 꼬리 비교의 기준선이다. 지수분포의 꼬리는 $e^{-\lambda x}$ 로 빨리 줄어든다 (가벼운 꼬리, Light Tail). 멱법칙의 $x^{-\alpha}$ 는 훨씬 느리게 줄어든다. 로그-로그 축에서 직선인가 휘는가 (Figure 4) 로 둘을 가른다.

6 HW2 문제 1(b): 영화 평점 데이터

강의 노트: §10.5 영화 평점, §10.2 모수 추정 (지수분포 MLE 예제).

문제 1(b)

What is the λ if the distribution is exponential?

영화 평균 평점 (01_movie_votes.csv, $n = 4392$) 에 $\hat{\lambda} = 1/\bar{x}$ 를 적용한다. 보고서의 답은 다음과 같다.

$\bar{x} = 6.227$	표본 평균
$\hat{\lambda} = 1/6.227 = 0.1606$	MLE

6.1 결과: 지수분포는 맞지 않는다

- 지수분포는 0 에서 가장 높다. 데이터는 약 6.3 에서 봉우리가 하나인 거의 대칭 모양이다.
- 모형 표본의 4% 가 20 을 넘는다. 평점으로 가능하지 않은 값이다.
- KS 거리 $D = 0.490$. 정규분포는 $D = 0.055$ 로 가장 잘 맞는다.

Table 7: 두 데이터에서 추정한 $\hat{\lambda}$ (보고서 값)

데이터	$\bar{x}$	$\hat{\lambda} = 1/\bar{x}$	KS 거리 D
1(a) 공항 노선 수	19.845	0.0504	0.379
1(b) 영화 평점	6.227	0.1606	0.490

Movie votes vs exponential $\lambda=0.1606$




Figure 8: 영화 평점에 지수분포 ($\hat{\lambda} = 0.1606$) 를 적합한 결과 (code/p1.py 가 생성). $D = 0.490$.