

HW2 문제 1 배경: 멱법칙 (Power Law) 과 지수분포 (Exponential)

Taek Lim

2026/09/28

HW2 두 문제에 공통으로 담긴 핵심

1. 분포는 데이터를 요약하는 **가정**이다.
2. 가정은 반드시 **시각적으로 검증**해야 한다.
3. 결과는 **데이터가 생성된 과정**으로 설명해야 한다.

Contents

1 멱법칙 분포란	4
1.1 PDF 는 어디서 왔나	5
1.2 정규분포인가	5
1.3 왜 파레토 분포라고 부르나	6
2 PDF 식의 각 조각은 왜 있나	7
2.1 핵심 모양: $x^{-\alpha}$	7
2.1.1 로그-로그 축에서 직선	8
2.2 왜 $x \geq x_{\min}$ 인가	10
2.3 정규화 상수와 $\alpha > 1$: 곡선 아래 넓이 = 1	10
2.4 작은 예제: $\alpha = 2, x_{\min} = 1$	11
2.5 α 가 평균과 분산을 결정한다	12
2.5.1 핵심 도구: x^{-p} 의 넓이는 언제 유한한가	12
2.5.2 평균과 분산은 넓이 계산이다	13
2.5.3 유한할 때의 값	13
2.5.4 데이터 분석에서 뜻하는 것	15
3 모수 추정 (Parameter Estimation) 이란	15
3.1 무엇인가: 모수는 분포의 손잡이다	16

3.2	왜 해야 하나: 숫자가 있어야 모형이 된다	16
3.3	어떻게 하나: 최대우도추정 (MLE)	16
3.4	그래서 왜 중요한가: 틀린 가정에도 숫자는 나온다	19
4	데이터에서 α 추정하기	20
5	HW2 문제 1: 모수 여덟 개 구하기 (단계별)	20
5.1	(a) 멱법칙 (Power Law): $\hat{\alpha}$	21
5.2	(b) 지수분포 (Exponential): $\hat{\lambda}$	22
5.3	(c) 균등분포 (Uniform): $[\hat{a}, \hat{b}]$	22
5.4	(d) 정규분포 (Normal): $\hat{\mu}, \hat{\sigma}$	24
5.5	KS 거리 (Kolmogorov–Smirnov Distance) 란	24
6	HW2 문제 1: 공항 노선 수 데이터	27
6.1	$\hat{\alpha} = 1.612$ 가 뜻하는 것	28
6.2	모형에서 표본 뽑기: 역변환 샘플링 (Inverse Transform Sampling)	28
6.3	적합이 맞는 범위	30
7	지수분포란	32
7.1	PDF, CDF, 평균과 분산 한눈에	32
7.2	λ 는 무엇인가	34
7.3	왜 λ 가 필요한가	34
7.4	데이터에서 λ 추정하기	34
7.5	왜 중요한가	34
8	HW2 문제 1: 영화 평점 데이터	35
8.1	결과: 지수분포는 맞지 않는다	35
8.2	왜 공항은 CCDF, 영화는 PDF 로 그렸나	36
8.3	그림 패널마다 답하는 질문	42
9	HW2 문제 2: 나이 필터 1–100 대 1–99	42







Figure 1: 역법칙의 80/20 을 사람과 양으로 나눠 본 그림, 그리고 정규분포. 읽는 법은 아래 목록.

Figure 1 읽는 법.

(a), (b) 같은 역법칙 $f(x) = 1.16 x^{-2.16}$, $x_{\min} = 1$.

- 가로축은 로그 눈금이다 ($1, 10, 10^2, \dots$). 꼬리가 길어 보통 눈금에는 다 들어가지 않는다.
- 두 패널 모두 전체 넓이 = 1 (100%). 넓이가 곧 비율이다.
- 파란 면: $x < 4$. 빨간 면: $x \geq 4$.

(a) 사람의 분포 넓이 = $\int f(x) dx$ = 사람의 비율.

- 파란 면: 사람의 80%.
- 빨간 면: 사람의 20%.

(b) 양의 분포 넓이 = $\int x f(x) dx$ = 양의 비율.

- 같은 사람들인데 넓이가 뒤집힌다. 파란 면: 양의 20%.
- 빨간 면: 양의 80%. 값 x 를 곱해 큰 x 쪽이 무거워졌다.

(c) 로렌츠 곡선 (a) 와 (b) 를 한 곡선으로 합친 것. 넓이가 아니라 높이로 읽는다.

- 가로축: 사람의 누적 비율 (적게 가진 사람부터).
- 세로축: 그 사람들이 가진 양의 누적 비율.
- 파란 실선: (a), (b) 의 멱법칙.
- 주황 일점쇄선: 실제 공항 노선 데이터.
- 회색 점선: 모두가 같은 양을 가질 때 ($y = x$).
- 검은 점 (0.8, 0.2): 하위 80% 가 양의 20% 를 가진다.
- 빨간 굵은 선: 상위 20% 가 양의 80% 를 가진다 (Section 1.3).
- 공항 데이터: 하위 80% 가 양의 16.2% 를 가진다.

(d) 표준정규분포 PDF 회색 점선, $\mu = 0, \sigma = 1$.

- 평균을 가운데 두고 좌우 대칭이다.
- 평균에서 멀어지면 매우 빨리 0 이 된다.

질문

Suppose the given data points follow a power law distribution: what is power law distribution? and alpha?

1 멱법칙 분포란

강의 노트: 4 장 “분포” §4.4 멱법칙 (04-distributions.tex, deck 6 slide 19-22). 요약 표는 §4.8.

멱법칙 (Power Law) 분포는 소수의 큰 값이 전체의 대부분을 차지하는 분포다. 대부분의 관측값은 작다. 아주 큰 값은 드물지만, 정규분포 (Normal) 나 지수분포 (Exponential) 보다 **훨씬 자주** 나온다. 이 성질을 **꼬리가 두껍다** (Heavy Tail) 고 한다.

파레토 분포 (Pareto Distribution), “80/20 법칙” 이라고도 부른다. 예: 공항별 노선 수, 도시 인구, 단어 빈도, 부의 분포.

확률밀도함수 (PDF) 는 다음과 같다.

$$f(x) = \frac{\alpha - 1}{x_{\min}} \left(\frac{x}{x_{\min}} \right)^{-\alpha}, \quad x \geq x_{\min}, \alpha > 1 \quad (1)$$

- $x_{\min}$: 멱법칙이 성립하기 시작하는 하한.
- α : 지수 (Power Law Exponent). 꼬리가 얼마나 빨리 줄어드는지 정한다.
- 앞의 $\frac{\alpha-1}{x_{\min}}$ 는 전체 넓이를 1 로 맞추는 정규화 상수다.

Figure 2 는 $x_{\min} = 1$ 에서 α 만 바꾼 세 곡선이다. 모두 $x_{\min}$ 에서 가장 높고 오른쪽으로 줄어든다.




Figure 2: 먹법칙 PDF $f(x) = (\alpha - 1)x^{-\alpha}$ ($x_{\min} = 1$). 파란 실선 $\alpha = 1.5$, 빨간 점선 $\alpha = 2.5$, 초록 일점쇄선 $\alpha = 3.5$. α 가 클수록 $x_{\min}$ 근처에 몰리고 꼬리가 빨리 줄어든다. α 가 작을수록 꼬리가 두꺼워 $x = 5$ 에서도 높이가 남는다.

1.1 PDF 는 어디서 왔나

질문

how did you get pdf for pwer law? is it normal? and why we call pareto distribution? buecauseu 80 normal 20 outlaw? whats its graph look like? can i have a figure at the begiging?

만든 식이 아니라 **먹법칙의 정의**에서 나온다. 먹법칙은 “확률이 x 의 거듭제곱으로 줄어든다”는 가정 하나다.

$$f(x) \propto x^{-\alpha} \quad (\alpha: \text{상수배를 빼면 같다})$$

이 가정에 빠진 것은 상수 하나뿐이고, 넓이를 1로 맞추면 정해진다 (Section 2.3). 그 결과가 Equation (1)다. 강의 노트 (deck 6 slide 19–22)와 Clauset et al. (2009)이 쓰는 표준형 (연속형)이 이것이다.

다른 길: 여집합 CDF 에서 미분. 파레토는 “ x 보다 큰 값의 비율”로 정의했다. 여기서 시작해도 같은 식이 나온다.

$$\begin{aligned} P(X \geq x) &= \left(\frac{x}{x_{\min}}\right)^{-(\alpha-1)} && x \text{보다 큰 비율 (Section 2.1.1의 기울기 } -(\alpha-1)) \\ f(x) &= -\frac{d}{dx}P(X \geq x) && \text{PDF 는 CDF 의 기울기} \\ &= (\alpha-1) \left(\frac{x}{x_{\min}}\right)^{-\alpha} \cdot \frac{1}{x_{\min}} && \text{거듭제곱 미분, 지수가 1 줄었다} \end{aligned}$$

Equation (1)와 같다.

1.2 정규분포인가

아니다. 정규분포 (Normal)와 모양이 정반대에 가깝다 (Figure 1).

Table 1: 역법칙과 정규분포 비교

	역법칙 (Power Law)	정규분포 (Normal)
가장 높은 곳	$x_{\min}$ (맨 왼쪽)	평균 μ (가운데)
모양	한쪽으로만 줄어듦	좌우 대칭 종 모양
값의 범위	$x \geq x_{\min} > 0$	모든 실수
꼬리	$x^{-\alpha}$, 느리게 줄어듦	$e^{-x^2/2}$, 매우 빨리 줄어듦
평균이 대표값인가	아니다 (소수가 끌어올림)	그렇다 (평균 = 중앙값)

예제: 공항 노선 수. 평균과 중앙값이 크게 다르다.

$\bar{x} = 19.8$
 중앙값 = 4
 82%

평균
 절반의 공항은 노선 4 개 이하
 평균보다 작은 공항의 비율

정규분포라면 평균 아래가 절반 (50%) 이어야 한다.

1.3 왜 파레토 분포라고 부르나

이탈리아 경제학자 빌프레도 파레토 (Vilfredo Pareto) 의 이름이다. 그는 1890 년대에 소득이 x 이상인 사람의 수가 x 의 거듭제곱으로 줄어든다는 것을 관찰했다. 흔히 전하는 예가 “이탈리아 땅의 80% 를 인구 20% 가 가진다” 이다. “80/20 법칙” (Pareto Principle) 이라는 이름은 뒤에 품질 관리 분야의 조셉 주란 (Joseph Juran) 이 붙였다.

“80 정상, 20 이상치” 가 아니다. 80/20 은 **사람의 20% 가 전체 양의 80% 를 가진다**는 뜻이다. 20% 는 버릴 이상치가 아니라 분포의 핵심인 긴 꼬리다 (Figure 1(a), (b) 의 빨간 면).

질문

가진 양이 그래프 아래면적을 이야기 하는거야? 그런데 그림 상으로 80 퍼센트 사람이 가진 양이 20 퍼센트로 안 보여 스케일 다르게 해서 보여줘야 하는 거아니야?

PDF 아래 넓이는 사람의 비율이지 양이 아니다. 두 넓이를 구별해야 한다.

$$\int_a^b f(x) dx$$

a 와 b 사이에 있는 **사람의 비율**

$$\int_a^b x f(x) dx$$

그 사람들이 가진 **양** (값 x 를 곱했다)

Figure 1(a) 의 넓이는 첫째 줄, (b) 의 넓이는 둘째 줄이다. 그래서 파란 면이 커 보이는 것이 맞다. 사람은 80% 가 거기 있다. 양은 둘째 줄인데, 큰 x 가 곱해지므로 꼬리 쪽 무게가 커진다. 그 양의 대부분은 그림 오른쪽 끝 ($x = 10$) 너머 먼 꼬리에 있다.

$$\int_4^{10} x f(x) dx / E[X] = 0.11$$

$$0.80 - 0.11 = 0.69$$

그림에 보이는 빨간 구간의 양

$x > 10$ 에 있는 양

보통 눈금으로는 꼬리가 잘린다. 그래서 Figure 1 는 가로축을 로그 눈금으로 바꾸고, (a) 사람과 (b) 양을 같은 축에 나란히 그렸다. 두 비율을 한 곡선으로 합치면 (c) 의 **로렌츠 곡선** (Lorenz Curve) 이 된다. 넓이가 아니라 **높이**로 읽는다. 가로 0.8 에서 곡선 높이가 0.2 면 하위 80% 가 20% 를 가진 것이다.

80/20 은 α 하나에서만 정확하다. 상위 비율 p 가 가진 양의 몫은 $\alpha > 2$ 일 때 다음과 같다.

$$\text{몫} = p^{(\alpha-2)/(\alpha-1)} \quad (x \cdot f(x) \text{ 를 꼬리에서 적분해 평균으로 나눈 값})$$

$\alpha = 2.16, p = 0.2$	가정
$(2.16 - 2)/(2.16 - 1) = 0.138$	지수
$0.2^{0.138} = 0.80$	상위 20% 가 80% 를 가진다

α 가 2 에 가까워지면 몫은 1(100%) 로 가고, α 가 커지면 줄어든다. 그래서 “80/20” 은 멱법칙의 한 예일 뿐 모든 멱법칙의 성질은 아니다.

예제: 공항 데이터. 노선이 많은 순으로 상위 20% 를 센다.

$3409 \times 0.2 = 682$	상위 20% 공항 수
83.8%	그 682 곳이 가진 노선의 몫

실제 데이터가 거의 80/20 이다. 적합한 $\hat{\alpha} = 1.612 < 2$ (Section 6) 로는 몫이 100% 에 가까워야 하는데, 실제 데이터는 큰 값에서 끊기기 (Cutoff) 때문에 83.8% 에서 멈춘다.

2 PDF 식의 각 조각은 왜 있나

$$f(x) = \frac{\alpha - 1}{x_{\min}} \left(\frac{x}{x_{\min}} \right)^{-\alpha}, \quad x \geq x_{\min}, \quad \alpha > 1$$

결론. 분포의 모양을 정하는 것은 $x^{-\alpha}$ 하나뿐이다. 나머지 ($x \geq x_{\min}, \alpha > 1$, 앞의 상수 $\frac{\alpha-1}{x_{\min}}$) 는 이 모양을 **올 바른 확률분포** (넓이가 유한하고 정확히 1) 로 만드는 장치다.

Table 2: 식의 각 조각과 그것이 막는 문제.

조각	하는 일	없으면 생기는 문제
$x^{-\alpha}$	천천히 줄어드는 꼬리 (heavy tail)	큰 값이 너무 드물게 나온다
$x \geq x_{\min}$	0 근처를 잘라 낸다	$x \rightarrow 0$ 에서 넓이가 무한대
$\alpha > 1$	꼬리 넓이를 유한하게	$x \rightarrow \infty$ 에서 넓이가 무한대
$\frac{\alpha-1}{x_{\min}}$	전체 넓이를 1 로	확률의 합이 1 이 아니다
$\frac{x}{x_{\min}}$	“최솟값의 몇 배인가” 로 읽기	(표기상 편의, 단위가 사라짐)

2.1 핵심 모양: $x^{-\alpha}$

고치는 문제. 부 (wealth), 도시 인구, 웹페이지 링크 수, 단어 빈도 같은 데이터에는 작은 값이 매우 많고, 아주 큰 값도 드물지만 무시할 수 없을 만큼 나온다. 정규분포 (Normal) 나 지수분포 (Exponential) 는 큰 값의 확률을 너무 빨리 0 으로 떨어뜨려 이런 데이터를 설명하지 못한다.

아이디어. 지수 e^{-x} 대신 거듭제곱 $x^{-\alpha}$ 로 줄어들게 한다. Table 3 이 그 차이를 숫자로 보여 준다.

Table 3: 같은 x 에서 지수분포와 멱법칙의 밀도 비교 ($\alpha = 2$).

x	지수 e^{-x}	멱법칙 x^{-2}
1	0.37	1
10	0.000045	0.01
100	3.7×10^{-44}	0.0001

$x = 100$ 에서 지수분포는 사실상 0 이지만 멱법칙은 여전히 1 만 분의 1 이다. 이것을 **두꺼운 꼬리** (heavy tail) 라고 부른다. Figure 3 은 같은 차이를 세로축 로그 눈금으로 그린 것이다.




Figure 3: 멱법칙 (파란 실선, $\alpha = 2$, $x_{\min} = 1$) 과 지수분포 (주황 점선, 비율 1, $x_{\min} = 1$ 에서 시작) 의 밀도. 세로축은 로그 눈금이다. $x = 10$ 에서 멱법칙은 10^{-2} , 지수분포는 약 $10^{-3.9}$ 로 약 80 배 차이 난다.

척도 불변 (scale-free). x 를 두 배로 늘리면 밀도는 x 가 얼마이든 늘 같은 비율로 줄어든다.

$$\frac{f(2x)}{f(x)} = \frac{(2x)^{-\alpha}}{x^{-\alpha}} = 2^{-\alpha} \quad (x \text{ 가 식에서 사라진다})$$

“1 만 원에서 2 만 원” 과 “1 억에서 2 억” 이 같은 비율로 줄어든다는 뜻이다. 지수분포는 $\frac{e^{-2x}}{e^{-x}} = e^{-x}$ 로 x 에 따라 달라지므로 이 성질이 없다.

α 와 꼬리의 두께. α 가 작을수록 꼬리가 두꺼워 극단값이 더 자주 나온다. α 가 클수록 꼬리가 빨리 줄어든다.

2.1.1 로그-로그 축에서 직선

Equation (1) 의 양변에 로그를 취한다.

$$\begin{aligned} f(x) &= C x^{-\alpha} && \text{상수를 } C \text{ 로 묶었다} \\ \log f(x) &= \log C - \alpha \log x && \text{양변에 로그} \end{aligned}$$

$\log x$ 에 대해 일차식이다. 그래서 **로그-로그 축에서 기울기가 $-\alpha$ 인 직선**이 된다. 지수분포는 같은 축에서 아래로 휘는 곡선이다 (Figure 4). 이것으로 둘을 구별한다.

여집합 CDF $P(X \geq x)$ 로 그리면 기울기는 $-(\alpha - 1)$ 이다. 적분하면서 지수가 하나 줄기 때문이다.




Figure 4: 로그-로그 축에서 멱법칙 (파란 실선) 과 지수분포 (빨간 점선). 멱법칙은 기울기 $-\alpha$ 의 직선, 지수분포는 아래로 휘는 곡선이다.

질문

2.1.1: explain why 지수 분포는 아래로 휘는지?

답: 기울기가 x 에 비례해 커지기 때문이다. 직선이란 기울기가 어디서나 같은 선이다. 그러니 로그-로그 축에서 두 분포의 **기울기**를 구해 비교하면 된다. 가로축을 $u = \ln x$ 로 둔다. 곧 $x = e^u$ 다.

멱법칙은 기울기가 상수다.

$$\begin{aligned} \ln f &= \ln C - \alpha \ln x = \ln C - \alpha u && u \text{ 에 대해 일차식} \\ \frac{d \ln f}{du} &= -\alpha && \text{기울기: } x \text{ 와 상관없이 일정} \end{aligned}$$

지수분포 $f(x) = \lambda e^{-\lambda x}$ 는 다르다.

$$\begin{aligned} \ln f &= \ln \lambda - \lambda x && \text{양변에 로그} \\ &= \ln \lambda - \lambda e^u && x = e^u \text{ 를 대입: } u \text{ 에 대해 일차식이 아니다} \\ \frac{d \ln f}{du} &= -\lambda e^u = -\lambda x && \text{기울기가 } -\lambda x \end{aligned}$$

기울기가 $-\lambda x$ 이므로 x 가 커질수록 기울기가 점점 더 가팔라진다. 오른쪽으로 갈수록 더 빨리 떨어지는 선, 곧 **아래로 휘는 곡선**이다. 로그의 밑을 10 으로 바꿔도 가로와 세로가 같은 비율 ($\ln 10$) 로 줄어 기울기는 같다.

직관. 로그 축에서 한 칸은 “10 배” 다. $1 \rightarrow 10$ 도 한 칸, $10 \rightarrow 100$ 도 한 칸이다. 멱법칙은 x 가 10 배가 될 때마다 f 가 늘 같은 비율 $10^{-\alpha}$ 로 줄어서 칸마다 같은 높이만큼 내려간다. 지수분포는 x 가 **더해진 양**만큼 줄어 든다. $1 \rightarrow 10$ 은 9 를 더한 것이고, $10 \rightarrow 100$ 은 90 을 더한 것이다. 같은 한 칸인데 뒤의 칸에서 10 배 더 많이 떨어진다.

예제. Figure 4 의 두 곡선 ($C = 1$, $\alpha = 2.5$ 멱법칙과 $\lambda = 1$ 지수분포 e^{-x}) 의 높이와 기울기를 몇 점에서 계산했다 (Table 4). 지수분포의 높이는 $\log_{10} e^{-x} = -0.4343 x$ 다.

Table 4: 로그-로그 축에서 높이 $\log_{10} f(x)$ 와 기울기. 멱법칙 ($\alpha = 2.5$) 은 기울기가 -2.5 로 일정하고, 지수 분포 (e^{-x}) 는 기울기 $-x$ 가 점점 가팔라진다.

x	$\log_{10} x$	멱법칙 높이	멱법칙 기울기	지수 높이	지수 기울기
1	0	0	-2.5	-0.43	-1
2	0.301	-0.75	-2.5	-0.87	-2
5	0.699	-1.75	-2.5	-2.17	-5
10	1	-2.5	-2.5	-4.34	-10

$x = 1$ 에서는 지수분포가 오히려 완만하다 (기울기 -1 대 -2.5). $x = 10$ 에서는 4 배 더 가파르다 (기울기 -10). 그래서 지수분포의 꼬리는 결국 멱법칙보다 훨씬 빨리 사라진다 (Figure 3 과 같은 이야기).

2.2 왜 $x \geq x_{\min}$ 인가

$x^{-\alpha}$ 는 $x \rightarrow 0$ 에서 무한대로 커진다. $\alpha > 1$ 이면 0 근처의 넓이도 무한대다.

$$\int_0^1 x^{-\alpha} dx = \left[\frac{x^{1-\alpha}}{1-\alpha} \right]_0^1 = \infty \quad (1-\alpha < 0 \text{ 이므로 } x \rightarrow 0 \text{ 에서 } x^{1-\alpha} \rightarrow \infty)$$

그래서 하한 $x_{\min} > 0$ 을 두고, 그 위에서만 멱법칙이 성립한다고 본다. 실제 데이터도 대개 어떤 값 이상의 꼬리에서만 멱법칙을 따른다.

2.3 정규화 상수와 $\alpha > 1$: 곡선 아래 넓이 = 1

질문

앞의 $\frac{\alpha-1}{x_{\min}}$ 는 전체 넓이를 1 로 맞추는 정규화 상수다. » area below distribution line => 1?

그렇다. PDF 곡선 아래 전체 넓이는 “어떤 값이든 하나는 나올 확률” 이므로 반드시 1 이다.

$$\int_{x_{\min}}^{\infty} f(x) dx = 1 \quad (\text{모든 PDF 의 조건})$$

$x^{-\alpha}$ 만으로는 넓이가 1 이 아니다. 그래서 앞에 상수 C 를 곱해 넓이를 1 로 맞춘다. 이 C 가 **정규화 상수** (Normalization Constant) 다.

C 구하기. $x^{-\alpha}$ 의 넓이를 먼저 구한다.

$$\begin{aligned} \int_{x_{\min}}^{\infty} x^{-\alpha} dx &= \left[\frac{x^{1-\alpha}}{1-\alpha} \right]_{x_{\min}}^{\infty} \\ &= 0 - \frac{x_{\min}^{1-\alpha}}{1-\alpha} \\ &= \frac{x_{\min}^{1-\alpha}}{\alpha-1} \end{aligned}$$

거듭제곱 적분

$\alpha > 1$ 이면 $x \rightarrow \infty$ 에서 $x^{1-\alpha} \rightarrow 0$

부호 정리

넓이가 1 이 되려면 C 는 이 값의 역수다.

$$\begin{aligned} C &= (\alpha - 1) x_{\min}^{\alpha-1} \\ f(x) &= (\alpha - 1) x_{\min}^{\alpha-1} x^{-\alpha} \\ &= \frac{\alpha - 1}{x_{\min}} \cdot x_{\min}^{\alpha} x^{-\alpha} \\ &= \frac{\alpha - 1}{x_{\min}} \left(\frac{x}{x_{\min}} \right)^{-\alpha} \end{aligned}$$

넓이의 역수

$f(x) = C x^{-\alpha}$ 에 C 를 대입

$$x_{\min}^{\alpha-1} = x_{\min}^{\alpha} / x_{\min}$$

$$x_{\min}^{\alpha} x^{-\alpha} = (x/x_{\min})^{-\alpha}$$

Equation (1) 와 같다. 둘째 줄에서 $\alpha > 1$ 이 쓰였다. $\alpha \leq 1$ 이면 넓이가 무한대라 어떤 C 로도 1 을 만들 수 없다. 이것이 $\alpha > 1$ 조건의 이유다. 마지막 형태로 쓰는 이유는 읽기 쉬워서다. $\frac{x}{x_{\min}}$ 은 “최솟값의 몇 배인가” 이고 단위 (원, 명) 가 사라진다.

예제. $\alpha = 2.5, x_{\min} = 1$.

$$\int_1^{\infty} x^{-2.5} dx = \frac{1}{1.5} = 0.667$$

상수 없이 넓이

$$C = 1.5$$

역수

$$1.5 \times 0.667 = 1$$

곱하면 넓이 1




Figure 5: $\alpha = 2.5, x_{\min} = 1$ 의 멱법칙 PDF $f(x) = 1.5 x^{-2.5}$ (빨간 점선). 빨간 면이 곡선 아래 넓이다. $x = 5$ 너머 꼬리까지 합치면 정확히 1 이다.

2.4 작은 예제: $\alpha = 2, x_{\min} = 1$

$$f(x) = \frac{2-1}{1} \left(\frac{x}{1} \right)^{-2} = \frac{1}{x^2}$$

x 이상일 확률 (꼬리 확률) 은 f 를 x 부터 적분해서 얻는다.

$$P(X \geq x) = \int_x^{\infty} \frac{1}{t^2} dt = \frac{1}{x} \quad (\text{일반형: } (x/x_{\min})^{-(\alpha-1)})$$

Table 5: $\alpha = 2$, $x_{\min} = 1$ 일 때 밀도와 꼬리 확률.

x	$f(x) = 1/x^2$	$P(X \geq x) = 1/x$
1	1	1 (전부)
2	0.25	0.5
10	0.01	0.1
100	0.0001	0.01

100 명 중 1 명은 최솟값의 100 배를 넘는다. 지수분포였다면 사실상 한 명도 없다 (Table 3).

2.5 α 가 평균과 분산을 결정한다

강의 노트: §4.4 먹법칙 (로그-로그 그림, deck 6 slide 22). 평균과 분산의 조건은 §4.8 요약 표의 “조건부 존재” 칸.

- $\alpha > 1$: 넓이가 1 이 되려면 (확률분포가 되려면) 필요하다.
- $\alpha > 2$: 이때만 평균이 유한하다. $E[X] = \frac{\alpha-1}{\alpha-2} x_{\min}$.
- $\alpha > 3$: 이때만 분산이 유한하다.

실제 데이터는 흔히 $2 < \alpha < 3$ 이다. 평균은 있어도 분산이 발산하는 경우가 많다.

질문

2.2 α 에 걸린 조건 (위 세 줄): explain more on this

2.5.1 핵심 도구: x^{-p} 의 넓이는 언제 유한한가

세 조건은 모두 한 가지 사실에서 나온다.

$$\int_1^{\infty} x^{-p} dx = \begin{cases} \frac{1}{p-1} & p > 1 \quad (\text{유한}) \\ \infty & p \leq 1 \quad (\text{발산}) \end{cases}$$

곡선이 x^{-p} 로 줄어들 때, p 가 1 보다 커야 꼬리가 충분히 빨리 줄어 넓이가 유한하다. $p = 1$ 이 경계다.

$$\begin{aligned} \int_1^{1000} x^{-1} dx &= \ln 1000 = 6.9 & p = 1: \text{구간을 늘리면} \\ \int_1^{10^6} x^{-1} dx &= \ln 10^6 = 13.8 & \text{넓이가 끝없이 커진다} \\ \int_1^{\infty} x^{-2} dx &= 1 & p = 2: \text{유한} \end{aligned}$$

2.5.2 평균과 분산은 넓이 계산이다

평균과 분산도 적분이다. 적분 안에 x 를 한 번, 두 번 더 곱할 뿐이다.

$$E[X] = \int_{x_{\min}}^{\infty} x \cdot Cx^{-\alpha} dx = C \int_{x_{\min}}^{\infty} x^{-(\alpha-1)} dx \quad x \text{ 를 한 번 곱했다: } p = \alpha - 1$$

$$E[X^2] = \int_{x_{\min}}^{\infty} x^2 \cdot Cx^{-\alpha} dx = C \int_{x_{\min}}^{\infty} x^{-(\alpha-2)} dx \quad \text{두 번 곱했다: } p = \alpha - 2$$

x 를 곱할 때마다 지수 p 가 1 씩 줄어 꼬리가 느려진다. 각각에 “ $p > 1$ ” 을 쓴다.

Table 6: x^k 를 곱한 적분이 유한해지는 조건. k 는 곱한 횟수.

구하는 것	적분 안의 꼬리	유한 조건 $p > 1$	결론
전체 넓이 ($k = 0$)	$x^{-\alpha}$	$\alpha > 1$	확률분포가 된다
평균 $E[X]$ ($k = 1$)	$x^{-(\alpha-1)}$	$\alpha - 1 > 1$	$\alpha > 2$
$E[X^2]$ ($k = 2$)	$x^{-(\alpha-2)}$	$\alpha - 2 > 1$	$\alpha > 3$

분산은 $\text{Var}[X] = E[X^2] - (E[X])^2$ 이므로 $E[X^2]$ 가 유한해야 유한하다. 그래서 분산의 조건은 $\alpha > 3$ 이다.

2.5.3 유한할 때의 값

$C = (\alpha - 1) x_{\min}^{\alpha-1}$ (Section 2.3) 를 넣고 적분하면 다음과 같다.

$$E[X] = \frac{\alpha - 1}{\alpha - 2} x_{\min} \quad \alpha > 2$$

$$E[X^2] = \frac{\alpha - 1}{\alpha - 3} x_{\min}^2 \quad \alpha > 3$$

$$\text{Var}[X] = \frac{\alpha - 1}{(\alpha - 2)^2(\alpha - 3)} x_{\min}^2 \quad \alpha > 3$$

분모의 $\alpha - 2$, $\alpha - 3$ 이 0 에 가까워지면 값이 무한대로 커진다. 식 모양에도 조건이 드러난다.

질문

2.5.3 explain how to get var[X] formular?

쓰는 도구 두 개.

- 거듭제곱의 꼬리 적분 (Section 2.3 에서 $p = \alpha$ 로 쓴 것과 같다):

$$\int_{x_{\min}}^{\infty} x^{-p} dx = \frac{x_{\min}^{1-p}}{p-1} \quad (p > 1)$$

- 분산의 정의를 풀어 쓴 꼴: $\text{Var}[X] = E[X^2] - (E[X])^2$. “제공의 평균 빼기 평균의 제곱” 이다.

그래서 순서는 $E[X]$ 구하기, $E[X^2]$ 구하기, 빼기의 세 단계다.

1 단계: $E[X]$. 적분 안의 꼬리는 $x^{-(\alpha-1)}$, 곧 $p = \alpha - 1$ 이다.

$$\begin{aligned}
 E[X] &= C \int_{x_{\min}}^{\infty} x^{-(\alpha-1)} dx && \text{위에서 구한 꼴} \\
 &= C \cdot \frac{x_{\min}^{2-\alpha}}{\alpha-2} && \text{도구, } p = \alpha - 1: 1 - p = 2 - \alpha, p - 1 = \alpha - 2 \\
 &= (\alpha - 1) x_{\min}^{\alpha-1} \cdot \frac{x_{\min}^{2-\alpha}}{\alpha-2} && C \text{ 대입} \\
 &= \frac{\alpha-1}{\alpha-2} x_{\min} && \text{지수 합: } (\alpha-1) + (2-\alpha) = 1
 \end{aligned}$$

2 단계: $E[X^2]$. 꼬리는 $x^{-(\alpha-2)}$, 곧 $p = \alpha - 2$ 이다.

$$\begin{aligned}
 E[X^2] &= C \int_{x_{\min}}^{\infty} x^{-(\alpha-2)} dx && \text{위에서 구한 꼴} \\
 &= C \cdot \frac{x_{\min}^{3-\alpha}}{\alpha-3} && \text{도구, } p = \alpha - 2: 1 - p = 3 - \alpha, p - 1 = \alpha - 3 \\
 &= (\alpha - 1) x_{\min}^{\alpha-1} \cdot \frac{x_{\min}^{3-\alpha}}{\alpha-3} && C \text{ 대입} \\
 &= \frac{\alpha-1}{\alpha-3} x_{\min}^2 && \text{지수 합: } (\alpha-1) + (3-\alpha) = 2
 \end{aligned}$$

3 단계: 빼기. 두 항 모두 $(\alpha-1)x_{\min}^2$ 을 가지고 있으니 먼저 묶고, 괄호 안을 통분한다.

$$\begin{aligned}
 \text{Var}[X] &= \frac{\alpha-1}{\alpha-3} x_{\min}^2 - \left(\frac{\alpha-1}{\alpha-2} x_{\min} \right)^2 && E[X^2] - (E[X])^2 \\
 &= \frac{\alpha-1}{\alpha-3} x_{\min}^2 - \frac{(\alpha-1)^2}{(\alpha-2)^2} x_{\min}^2 && \text{제곱을 풀었다} \\
 &= (\alpha-1) x_{\min}^2 \left[\frac{1}{\alpha-3} - \frac{\alpha-1}{(\alpha-2)^2} \right] && (\alpha-1) x_{\min}^2 \text{ 로 묶었다} \\
 &= (\alpha-1) x_{\min}^2 \cdot \frac{(\alpha-2)^2 - (\alpha-1)(\alpha-3)}{(\alpha-3)(\alpha-2)^2} && \text{통분: 공통 분모 } (\alpha-3)(\alpha-2)^2
 \end{aligned}$$

분자를 전개한다. 이 식의 핵심은 분자가 1로 줄어든다는 것이다.

$$\begin{aligned}
 (\alpha-2)^2 &= \alpha^2 - 4\alpha + 4 && \text{전개} \\
 (\alpha-1)(\alpha-3) &= \alpha^2 - 4\alpha + 3 && \text{전개} \\
 (\alpha^2 - 4\alpha + 4) - (\alpha^2 - 4\alpha + 3) &= 1 && \text{빼면 } \alpha \text{ 가 모두 지워진다}
 \end{aligned}$$

분자 = 1 을 넣으면

$$\text{Var}[X] = \frac{\alpha-1}{(\alpha-3)(\alpha-2)^2} x_{\min}^2 \quad (\alpha > 3)$$

으로 위의 식과 같다. 아래 예제 1($\alpha = 4, x_{\min} = 1$) 에서 두 방법 ($3 - 1.5^2$ 와 $3/(1 \cdot 2^2)$) 이 똑같이 0.75 를 주는 것으로 확인할 수 있다.

예제 1: $\alpha = 4$, $x_{\min} = 1$ (셋 다 유한).

$$E[X] = 3/2 = 1.5$$

평균

$$E[X^2] = 3/1 = 3$$

제곱의 평균

$$\text{Var}[X] = 3 - 1.5^2 = 0.75$$

분산 (공식으로도 $3/(4 \cdot 1) = 0.75$)

예제 2: $\alpha = 2.5$, $x_{\min} = 1$ (평균만 유한).

$$E[X] = 1.5/0.5 = 3$$

평균은 유한

$$\alpha - 2 = 0.5 \leq 1$$

$E[X^2]$ 의 꼬리 $x^{-0.5}$: 발산, 분산은 무한

2.5.4 데이터 분석에서 뜻하는 것

“평균이 무한”은 실제 데이터의 평균이 무한대라는 뜻이 아니다. 유한한 표본의 평균은 언제나 숫자 하나로 계산된다. 뜻하는 것은 **표본 평균이 한 값으로 수렴하지 않는다**는 것이다. 표본을 늘릴수록 전보다 더 큰 극단값이 들어와 표본 평균이 계속 쏠린다.

- $\alpha > 3$: 평균, 분산 모두 안정. 표본을 늘리면 정해진 값에 다가간다.
- $2 < \alpha \leq 3$: 표본 평균은 수렴하지만, 표본 분산 (표준편차)은 표본이 커질수록 계속 커진다. 평균 $\pm$ 표준편차 같은 요약이 믿을 만하지 않다.
- $1 < \alpha \leq 2$: 표본 평균조차 수렴하지 않는다. 평균보다 중앙값 (Median)이 나은 요약이다.

문제 1의 공항 데이터는 $\hat{\alpha} = 1.612$ 로 마지막 경우다 (Section 6).

α 가 작을수록 꼬리가 두껍고, “상위 소수가 전체 양의 대부분을 가진다”(80/20)는 현상이 강해진다. 이 부분은 Figure 1의 사람 대 양 그림과 이어진다.

3 모수 추정 (Parameter Estimation) 이란

질문

모수 추정? 영어로 말해주고 이게 뭔지 왜 해야 하는지 어떻게 하는지 그래서 왜 중요한지?

In brief.

What 분포의 “손잡이”(모수)를 데이터에 맞게 돌려 값을 정하는 일이다.

Why 분포 이름만으로는 계산도 생성도 할 수 없다. 숫자가 있어야 모형이 된다.

How 데이터가 나올 확률 (우도)이 가장 커지는 값을 고른다 (MLE).

Caution 틀린 분포를 골라도 숫자는 나온다. 그래서 그림으로 검증한다.

3.1 무엇인가: 모수는 분포의 손잡이다

모수 (Parameter) 는 분포의 모양과 위치를 정하는 숫자다. “지수분포” 는 하나의 분포가 아니라 λ 값마다 하나씩 있는 분포들의 **가족 (Family)** 이다. **모수 추정 (Parameter Estimation)** 은 이 가족 가운데 데이터에 가장 맞는 하나를 고르는 일, 곧 모수 값을 데이터로 정하는 일이다. 추정한 값에는 모자를 씌워 $\hat{\lambda}$, $\hat{\alpha}$ 처럼 쓴다 (참값 λ 와 구별).

질문

why do you use hat? what does that mean?

모자 (Hat) 의 뜻. 모자 (^) 는 “데이터로 추정한 값”(Estimate) 이라는 표시다. “알파 햇”(alpha hat) 이라고 읽는다. 모자가 없는 기호는 데이터를 만든 과정 자체의 값, 곧 우리가 모르는 참값 (True Value) 이다.

- α : 참값. 하나로 고정되어 있지만 모른다.
- $\hat{\alpha}$: 가진 표본으로 계산한 값. 공항 데이터에서 1.612.

구별하는 이유는 우리가 가진 것이 세상 전체가 아니라 **표본 (Sample)** 하나라서다. 공항 3409 곳은 2017 년 2 월 한 시점의 표본이다. 다른 달의 데이터로 같은 공식을 계산하면 1.612 가 아니라 1.60 이나 1.63 이 나올 수 있다. $\hat{\alpha}$ 는 가진 데이터에 따라 흔들리고, 이 흔들림을 **표본 오차 (Sampling Error)** 라 한다. 모자는 “이 숫자는 참값이 아니라 우리 데이터에서 나온 추측” 임을 기호로 드러낸다. 같은 구분을 기호로 하는 경우도 있다. 표본 평균 (Sample Mean) 은 $\bar{x}$, 참 평균은 μ 다.

Table 7: HW2 문제 1 의 네 분포 가족과 모수.

분포 가족	모수	모수가 정하는 것
멱법칙 (Power Law)	α (와 $x_{\min}$)	꼬리가 줄어드는 빠르기
지수분포 (Exponential)	λ	줄어드는 비율, 평균 $1/\lambda$
균등분포 (Uniform)	a, b	값이 나올 수 있는 범위
정규분포 (Normal)	μ, σ	중심과 퍼짐

3.2 왜 해야 하나: 숫자가 있어야 모형이 된다

“이 데이터는 지수분포다” 라는 말만으로는 할 수 있는 것이 없다. λ 가 정해져야 비로소 다음이 가능하다.

- **계산:** “노선이 50 개 넘는 공항의 비율” 처럼 확률을 구한다.
- **생성:** 그 분포에서 난수 표본을 뽑는다. 과제가 요구하는 일이다.
- **비교:** 네 모형을 같은 데이터 위에 겹쳐 그려 어느 것이 맞는지 본다.

3.3 어떻게 하나: 최대우도추정 (MLE)

아이디어. 모수 후보마다 “이 모수라면 지금 가진 데이터가 나올 확률이 얼마인가” 를 계산하고, 그 확률이 가장 큰 후보를 고른다. 그 확률을 **우도 (Likelihood)** 라 하고, 이 방법을 **최대우도추정 (MLE, Maximum Likelihood Estimation)** 이라 한다. 관측값이 서로 독립이면 우도는 각 점의 밀도를 곱한 것이다.

$$L(\lambda) = f(x_1) f(x_2) \cdots f(x_n) \quad (\text{모수 } \lambda \text{ 일 때 데이터 전체의 “그럴듯함”})$$

예제: 지수분포, 데이터 $\{1, 2, 4\}$. $f(x) = \lambda e^{-\lambda x}$ 이므로

$$\begin{aligned} L(\lambda) &= \lambda e^{-\lambda \cdot 1} \cdot \lambda e^{-\lambda \cdot 2} \cdot \lambda e^{-\lambda \cdot 4} \\ &= \lambda^3 e^{-7\lambda} \end{aligned}$$

세 점의 밀도를 곱했다

지수끼리 더했다: $1 + 2 + 4 = 7$

후보 세 개를 넣어 본다 (Table 8).

Table 8: 지수분포 우도 $L(\lambda) = \lambda^3 e^{-7\lambda}$ 를 세 후보에서 계산한 값.

λ	λ^3	$e^{-7\lambda}$	$L(\lambda)$
0.2	0.0080	0.2466	0.00197
$3/7 \approx 0.43$	0.0787	0.0498	0.00392
1	1	0.00091	0.00091

$\lambda = 3/7$ 에서 가장 크다. 미분으로 정확히 구하면 다음과 같다.

$$\begin{aligned} \ln L &= 3 \ln \lambda - 7\lambda \\ \frac{d \ln L}{d\lambda} &= \frac{3}{\lambda} - 7 = 0 \\ \hat{\lambda} &= \frac{3}{7} = \frac{1}{\bar{x}} \end{aligned}$$

곱을 합으로 바꾸려고 로그

꼭대기에서 기울기 0

$\bar{x} = 7/3$: 평균의 역수

일반적으로 지수분포의 MLE 는 $\hat{\lambda} = 1/\bar{x}$ 다. 다른 분포도 같은 방법으로 공식이 나온다 (Table 11).

질문

3.3: only shows exponential distribution, how to get power law distribution?

예제: 멱법칙 (Power Law), 같은 데이터 $\{1, 2, 4\}$. 순서는 지수분포와 똑같다. 우도 (Likelihood) 를 쓰고, 로그를 씌우고, 미분해서 0 으로 둔다. 한 가지 다른 점은 $x_{\min}$ 이다. $x_{\min}$ 은 먼저 정해 두고 α 만 추정한다. 여기서 HW2 코드와 같이 데이터의 최솟값 $x_{\min} = 1$ 로 둔다.

Equation (1) 에 로그를 씌워 점 하나의 로그 밀도 (Log Density) 를 구한다.

질문

$\ln f(x_i) = \ln \frac{\alpha-1}{x_{\min}} - \alpha \ln \frac{x_i}{x_{\min}}$... how did you get this?

로그 법칙 (Logarithm Rules) 세 개만 쓴다 (Table 9). 로그를 쓰는 이유는 곱을 합으로 바꾸기 위해서다. 우도는 n 개 밀도의 곱이라, 로그를 씌우면 다루기 쉬운 합이 된다.

Table 9: 유도에 쓰는 로그 법칙 세 개와 숫자로 확인한 값.

법칙	식	숫자 예
곱은 합	$\ln(A \cdot B) = \ln A + \ln B$	$\ln(2 \cdot 3) = 0.693 + 1.099 = 1.792$
나눗셈은 빼기	$\ln(A/C) = \ln A - \ln C$	$\ln(6/2) = 1.792 - 0.693 = 1.099$
거듭제곱은 곱	$\ln(B^p) = p \ln B$	$\ln(2^3) = 3 \times 0.693 = 2.079$

Equation (1) 는 “상수 $\times$ 거듭제곱” 의 꼴이다. 앞의 상수를 $A = \frac{\alpha-1}{x_{\min}}$, 뒤의 거듭제곱을 B^p 로 보면 ($B = \frac{x_i}{x_{\min}}$, $p = -\alpha$) 한 줄에 법칙 하나씩 쓴다.

$$\begin{aligned}\ln f(x_i) &= \ln \left[\frac{\alpha-1}{x_{\min}} \cdot \left(\frac{x_i}{x_{\min}} \right)^{-\alpha} \right] && \text{Equation (1) 에 로그를 씌웠다} \\ &= \ln \frac{\alpha-1}{x_{\min}} + \ln \left(\frac{x_i}{x_{\min}} \right)^{-\alpha} && \text{곱은 합: } \ln(A \cdot B^p) = \ln A + \ln B^p \\ &= \ln \frac{\alpha-1}{x_{\min}} - \alpha \ln \frac{x_i}{x_{\min}} && \text{거듭제곱은 곱: } \ln B^{-\alpha} = -\alpha \ln B \\ &= \ln(\alpha-1) - \ln x_{\min} - \alpha \ln \frac{x_i}{x_{\min}} && \text{나눗셈은 빼기: } \ln \frac{\alpha-1}{x_{\min}} = \ln(\alpha-1) - \ln x_{\min}\end{aligned}$$

숫자로 확인. $\alpha = 2.5$, $x_{\min} = 2$, $x_i = 4$ 로 두 쪽을 따로 계산한다.

$$\begin{aligned}f(4) &= \frac{1.5}{2} \cdot 2^{-2.5} = 0.75 \times 0.1768 = 0.1326 && \text{밀도를 먼저 계산} \\ \ln 0.1326 &= -2.021 && \text{왼쪽: 그 값에 로그} \\ \ln 1.5 - \ln 2 - 2.5 \ln 2 &= 0.405 - 0.693 - 1.733 = -2.021 && \text{오른쪽: 마지막 줄의 식}\end{aligned}$$

두 값이 같다. n 개 점을 모두 더한다. 로그 우도 (Log-Likelihood) 가 된다.

$$\begin{aligned}\ln L(\alpha) &= n \ln(\alpha-1) - n \ln x_{\min} - \alpha S && S = \sum_i \ln(x_i/x_{\min}) \text{ 로 묶었다} \\ \frac{d \ln L}{d \alpha} &= \frac{n}{\alpha-1} - S = 0 && \alpha \text{ 로 미분, } \ln x_{\min} \text{ 항은 상수라 사라진다} \\ \alpha-1 &= \frac{n}{S} && \text{정리} \\ \hat{\alpha} &= 1 + \frac{n}{\sum_i \ln(x_i/x_{\min})} && \text{Equation (2) 과 같다}\end{aligned}$$

$\{1, 2, 4\}$ 에 넣는다.

$$\begin{aligned}S &= \ln 1 + \ln 2 + \ln 4 = 0 + 0.693 + 1.386 = 2.079 && \text{로그의 합} \\ \hat{\alpha} &= 1 + 3/2.079 = 2.443 && \text{추정값}\end{aligned}$$

후보를 넣어 보면 정말 $\hat{\alpha}$ 에서 우도가 가장 크다 (Table 10). $x_{\min} = 1$ 이면 $L(\alpha) = (\alpha-1)^3 (1 \cdot 2 \cdot 4)^{-\alpha} = (\alpha-1)^3 8^{-\alpha}$ 이다.

Table 10: 역법칙 우도 $L(\alpha) = (\alpha-1)^3 8^{-\alpha}$ 를 세 후보에서 계산한 값.

α	$(\alpha-1)^3$	$8^{-\alpha}$	$L(\alpha)$
2	1	0.01563	0.0156
2.443	3.003	0.00622	0.0187
3	8	0.00195	0.0156

지수분포와 비교하면 차이는 하나다. 지수분포는 x_i 자체의 평균을 쓰고 ($\hat{\lambda} = 1/\bar{x}$), 역법칙은 $\ln(x_i/x_{\min})$ 의 평균을 쓴다 ($\hat{\alpha} = 1 + 1/\ln(x/x_{\min})$). 역법칙은 “몇 배인가” 로 재는 분포라 로그 눈금에서 평균을 낸다.

Table 11: HW2 문제 1 의 네 분포에서 MLE 로 얻는 추정 공식.

분포	추정 공식
역법칙	$\hat{\alpha} = 1 + n / \sum_i \ln(x_i / x_{\min})$ (Section 4)
지수분포	$\hat{\lambda} = 1 / \bar{x}$
균등분포	$\hat{a} = \min_i x_i, \hat{b} = \max_i x_i$
정규분포	$\hat{\mu} = \bar{x}, \hat{\sigma} = \text{표본 표준편차}$

질문

균등 분포 standard deviation?

균등분포 (Uniform Distribution) 의 표준편차 (Standard Deviation). 균등분포의 모수는 a, b 뿐이라 표준편차를 따로 추정하지 않는다. a, b 가 정해지면 표준편차도 따라 정해진다.

$$\sigma = \frac{b-a}{\sqrt{12}} \approx 0.289(b-a) \quad (\text{범위 폭의 약 } 29\%)$$

유도는 분산 (Variance) = $E[X^2] - (E[X])^2$ (Section 2.5) 를 그대로 쓴다. 밀도 (Density) 는 $[a, b]$ 위에서 $f(x) = \frac{1}{b-a}$ 로 일정하다.

$$\begin{aligned} E[X] &= \int_a^b \frac{x}{b-a} dx = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2} && \text{가운데 점} \\ E[X^2] &= \int_a^b \frac{x^2}{b-a} dx = \frac{b^3 - a^3}{3(b-a)} = \frac{a^2 + ab + b^2}{3} && b^3 - a^3 = (b-a)(a^2 + ab + b^2) \\ \text{Var}[X] &= \frac{a^2 + ab + b^2}{3} - \frac{a^2 + 2ab + b^2}{4} && \text{빼기} \\ &= \frac{4a^2 + 4ab + 4b^2 - 3a^2 - 6ab - 3b^2}{12} && \text{통분: 분모 12} \\ &= \frac{a^2 - 2ab + b^2}{12} = \frac{(b-a)^2}{12} && \text{정리} \end{aligned}$$

제곱근을 씌우면 $\sigma = (b-a)/\sqrt{12}$ 다.

예: 영화 평점에 균등분포를 맞추면. 01_movie_votes.csv($n = 4392$, python 으로 계산, 2026/09/29) 의 최솟값과 최댓값이 $\hat{a} = 1.9, \hat{b} = 8.5$ 다.

$$\begin{aligned} (8.5 - 1.9) / \sqrt{12} &= 6.6 / 3.464 = 1.91 && \text{균등분포가 예측하는 표준편차} \\ 0.89 &&& \text{실제 데이터의 표본 표준편차} \end{aligned}$$

균등분포는 실제보다 두 배 넘게 퍼진다고 말한다. 실제 평점은 평균 6.2 근처에 몰려 있는데, 균등분포는 2 점과 8 점이 6 점만큼 흔하다고 가정하기 때문이다. 이것도 공식은 숫자를 내지만 모형은 틀린 경우다.

3.4 그래서 왜 중요한가: 틀린 가정에도 숫자는 나온다

Table 11 의 공식은 어떤 데이터에 넣어도 숫자를 돌려준다. 공식은 “이 가족이 맞다면 어느 값이 가장 나은가”에만 답한다. “이 가족이 맞는가”에는 답하지 않는다.

예: 공항 데이터에 정규분포를 맞추면. 01_airport_routes.csv($n = 3409$) 에 정규분포 공식을 넣으면 (python 으로 계산, 2026/09/29)

$$\begin{aligned}\hat{\mu} &= 19.8, \hat{\sigma} = 53.5 && \text{공식은 문제없이 숫자를 낸다} \\ P(X < 0) &= \Phi\left(\frac{0-19.8}{53.5}\right) = 0.355 && \text{이 모형이 말하는 “노선 수가 음수인 공항” 의 비율}\end{aligned}$$

노선 수는 음수일 수 없는데, 이 모형에서 표본을 뽑으면 약 36% 가 음수로 나온다. 실제 데이터의 중앙값은 4 인데 $\hat{\mu} = 19.8$ 이다. 소수의 허브 공항 (최대 915) 이 평균을 끌어올렸기 때문이다 (Section 2.5 의 “평균이 한 값으로 수렴하지 않는다” 와 같은 이야기).

숫자만 보면 이 잘못이 보이지 않는다. **추정한 모수로 표본을 생성해 실제 데이터와 겹쳐 그리면** 곧바로 보인다. 과제가 PDF, CDF, QQ plot 중 하나로 확인하라고 하는 이유이고, 첫 쪽의 핵심 2(가정은 시각적으로 검증한다) 가 뜻하는 것이다.

4 데이터에서 α 추정하기

강의 노트: 10 장 “과제 2” §10.2 모수 추정 (hw02-data-distributions.tex, 역법칙 MLE 예제).

최대우도추정 (MLE, Maximum Likelihood Estimation; Clauset et al. 2009) 을 쓴다.

$$\hat{\alpha} = 1 + \frac{n}{\sum_{i=1}^n \ln(x_i/x_{\min})} \quad (2)$$

HW2 코드 (hw2/code/common.py 의 fit_power_law) 도 이 식을 쓰고, $x_{\min}$ 은 데이터의 최소값으로 둔다. 로그-로그 히스토그램에 직선을 그어 기울기를 읽는 방법은 편향이 커서 권장하지 않는다. 직선이 맞는지 눈으로 확인하는 용도로만 쓴다.

예제. 데이터 $\{1, 2, 4, 8\}$, $x_{\min} = 1$, $n = 4$.

$$\begin{aligned}\ln(1/1) &= 0 \\ \ln(2/1) &= 0.693 \\ \ln(4/1) &= 1.386 \\ \ln(8/1) &= 2.079 \\ 0 + 0.693 + 1.386 + 2.079 &= 4.159 && \text{분모 (로그의 합)} \\ 1 + 4/4.159 &= 1.962 && \hat{\alpha}\end{aligned}$$

$\hat{\alpha} \approx 1.96 < 2$ 이므로, 이 모형에서는 평균이 유한하지 않다.

5 HW2 문제 1: 모수 여덟 개 구하기 (단계별)

질문

I need airport and movie data for p1-b? ... I need steps to find each and add them into notes

먼저 구조. 문제 1 의 (a)–(d) 는 데이터셋이 아니라 **모형** (Model) 이다. 과제 원문은 “For each of these datasets, consider the following models: (a) ... (d)” 다. 그래서 모형 네 개를 데이터 두 개에 각각 적용해 모수를 여덟 번 구한다 (Table 12). 제출 템플릿도 “Airport data” 와 “Movie Rating data” 아래에 같은 문항 네 개를 두 번 둔다.

Table 12: 문제 1 의 모수 여덟 개와 KS 거리 D (hw2/code/run_all.py 출력, 2026/09/29). D 가 작을수록 모형 표본이 데이터와 가깝다. 데이터마다 가장 작은 D 를 굵게 적었다.

데이터	(a) 역법칙 $\hat{\alpha}$	(b) 지수 $\hat{\lambda}$	(c) 균등 $[\hat{a}, \hat{b}]$	(d) 정규 $\hat{\mu}, \hat{\sigma}$
공항 노선 수	1.612	0.0504	[1, 915]	19.845, 53.506
KS D	0.209	0.397	0.856	0.365
영화 평점	1.851	0.1606	[1.9, 8.5]	6.227, 0.893
KS D	0.490	0.481	0.380	0.048

아래 네 소절은 모형 하나씩, 공식 $\rightarrow$ 코드 한 줄 $\rightarrow$ 두 데이터에 넣은 숫자의 순서로 적는다. 공식이 왜 그런지는 Section 3(최대우도추정, MLE) 에 있다. 숫자는 모두 python 으로 다시 계산해 코드 출력과 맞췄다.

Table 13: 단계에 쓰는 기초 값 (python 으로 계산, 2026/09/29).

값	공항 노선 수	영화 평점
개수 n	3409	4392
합 $\sum x_i$	67652	27348.7
최솟값 $\min x_i$	1	1.9
최댓값 $\max x_i$	915	8.5
편차 제곱합 $\sum (x_i - \bar{x})^2$	9756906.22	3503.28

5.1 (a) 역법칙 (Power Law): $\hat{\alpha}$

공식. $\hat{\alpha} = 1 + n / \sum_i \ln(x_i / x_{\min})$ (Equation (2)), $x_{\min}$ 은 데이터 최솟값.

```
x_min = x.min()
alpha = 1 + len(x) / np.log(x / x_min).sum()
```

단계.

1. $x_{\min}$ 을 정한다 (최솟값).
2. 값마다 $x_{\min}$ 으로 나누고 로그를 씌운다: $\ln(x_i / x_{\min})$.
3. 모두 더한다: S .
4. $\hat{\alpha} = 1 + n / S$.

공항: $x_{\min} = 1$, $S = 5569.43$, $\hat{\alpha} = 1 + 3409 / 5569.43 = 1.612$ (Table 19)

영화: $x_{\min} = 1.9$, $S = 5163.93$, $\hat{\alpha} = 1 + 4392 / 5163.93 = 1.851$ $\ln(x_i / 1.9)$ 의 합

5.2 (b) 지수분포 (Exponential): $\hat{\lambda}$

공식. $\hat{\lambda} = 1/\bar{x}$ (평균의 역수, Section 3 의 예제).

```
lam = 1 / x.mean()
```

단계.

1. 평균을 구한다: $\bar{x} = \sum x_i/n$.
2. 역수를 취한다: $\hat{\lambda} = 1/\bar{x}$.

공향: $\bar{x} = 67652/3409 = 19.845$, $\hat{\lambda} = 1/19.845 = 0.0504$

영화: $\bar{x} = 27348.7/4392 = 6.227$, $\hat{\lambda} = 1/6.227 = 0.1606$

5.3 (c) 균등분포 (Uniform): $[\hat{a}, \hat{b}]$

공식. $\hat{a} = \min_i x_i$, $\hat{b} = \max_i x_i$. 균등분포의 밀도는 구간 안에서 $1/(b-a)$ 로 일정하다. 모든 점을 담는 가장 좁은 구간일 때 밀도가 가장 커서 우도가 가장 크다. 그래서 최솟값과 최댓값이다.

```
a, b = x.min(), x.max()
```

공향: $[\hat{a}, \hat{b}] = [1, 915]$

영화: $[\hat{a}, \hat{b}] = [1.9, 8.5]$

질문

$[a, b] = [1, 915]$, the minimum and maximum route counts (MLE): explain this?

왜 최솟값과 최댓값인가. 우도 (Likelihood) 는 모든 점의 밀도를 곱한 값이다. 데이터 n 개가 모두 $[a, b]$ 안에 있으면

$$L(a, b) = \underbrace{\frac{1}{b-a} \times \cdots \times \frac{1}{b-a}}_{n\text{개}} = \left(\frac{1}{b-a} \right)^n \quad (\text{폭이 좁을수록 커진다})$$

이고, 하나라도 밖에 있으면 그 점의 밀도가 0 이라 $L = 0$ 이다. 그래서 폭을 최대한 좁히되 모든 점을 담아야 한다. 답은 **모든 데이터를 담는 가장 좁은 구간**, $\hat{a} = \min_i x_i$, $\hat{b} = \max_i x_i$ 다.

예제: 데이터 $\{2, 5, 7\}$. 후보 구간 셋의 우도를 비교한다 (Table 14).

Table 14: 데이터 $\{2, 5, 7\}$ 에서 균등분포 후보 구간의 우도 $L = (1/(b - a))^3$.

후보 구간	모든 점을 담나	L
$[0, 10]$	예	$(1/10)^3 = 0.001$
$[2, 7]$	예	$(1/5)^3 = \mathbf{0.008}$ (가장 큼)
$[3, 7]$	아니요 (2 가 밖)	0

넓은 구간은 담기는 하지만 밀도가 낮아 우도가 작고, 좁은 구간은 점을 놓쳐 0 이 된다. 공항 데이터에서는 노선 1 개 (713 곳) 와 915 개 (ATL) 가 양 끝이고, 모형의 밀도는 $1/914$ 로 모든 노선 수가 똑같이 흔하다고 말한다. 참고로 최솟값과 최댓값은 참 범위보다 약간 좁게 잡히는 경향이 있어 (표본이 참 끝점에 정확히 닿기 어렵다) 편향 (Bias) 을 고친 추정량도 있지만, 과제의 기준은 MLE 다.

질문

why did you mention MLE?

왜 “MLE” 라고 밝히나. 같은 질문에도 추정 방법에 따라 답이 달라지기 때문이다. 균등분포의 $[a, b]$ 를 구하는 흔한 방법 둘을 비교한다 (Table 15, python 으로 계산, 2026/09/30).

- **MLE:** 모든 데이터를 담는 가장 좁은 구간, $[\min, \max]$.
- **적률법** (Method of Moments): 모형의 평균 $(a + b)/2$ 와 표준편차 $(b - a)/\sqrt{12}$ 를 데이터의 $\bar{x}, s$ 에 맞춘다. 풀면 $\bar{x} \pm \sqrt{3} s$ 다.

Table 15: 같은 데이터에 두 추정 방법을 쓴 균등분포 구간.

방법	공항 노선 수	영화 평점
MLE $[\min, \max]$	$[1, 915]$	$[1.9, 8.5]$
적률법 $\bar{x} \pm \sqrt{3} s$	$[-72.8, 112.5]$	$[4.68, 7.77]$

적률법은 이 데이터에서 이상한 답을 낸다. 공항은 음수 노선 수를 구간에 넣으면서도 노선 915 개인 ATL 을 구간 밖에 둔다. 영화는 1.9–4.68 점과 7.77–8.5 점 영화를 “나올 수 없다” 고 말한다. MLE 를 고른 이유는 세 가지다.

1. 네 모형에 같은 원리를 쓴다. $\hat{\alpha}, \hat{\lambda}, \hat{\mu}$ 가 모두 MLE 다 ($\hat{\sigma}$ 만 $n - 1$ 로 나눈다). 한 모형만 다른 방법이면 공정한 비교가 아니다.
2. MLE 구간은 정의상 모든 관측값을 담는다. 그래서 모형 표본을 데이터와 겹쳐 그리는 비교가 성립한다.
3. 강의의 과제 2 장 (모수 추정 절) 도 MLE 로 다룬다.

보고서 답의 “(MLE)” 는 답을 계산한 규칙의 이름이다. 그게 없으면 “다른 방법이면 다르지 않나” 라는 질문이 남는다.

5.4 (d) 정규분포 (Normal): $\hat{\mu}$, $\hat{\sigma}$

공식. $\hat{\mu} = \bar{x}$, $\hat{\sigma} = \sqrt{\sum_i (x_i - \bar{x})^2 / (n - 1)}$. HW2 코드는 $n - 1$ 로 나눈다 (표본 표준편차 (Sample Standard Deviation), ddof=1). MLE 는 n 으로 나누지만, n 이 수천이라 차이는 소수 넷째 자리 이하다.

```
mu, sigma = x.mean(), x.std(ddof=1)
```

단계.

1. 평균 $\hat{\mu} = \bar{x}$ ((b) 에서 이미 구했다).
2. 값마다 평균과의 차이를 제공해 더한다 (편차 제곱합).
3. $n - 1$ 로 나누고 제곱근을 씌운다.

$$\text{공항: } \hat{\mu} = 19.845, \hat{\sigma} = \sqrt{9756906.22/3408} = \sqrt{2862.94} = 53.506$$

$$\text{영화: } \hat{\mu} = 6.227, \hat{\sigma} = \sqrt{3503.28/4391} = \sqrt{0.7978} = 0.893$$

다음 단계. 모수를 구한 것은 절반이다. 각 모형에서 표본을 뽑아 (Section 6.2) 데이터와 겹쳐 그리고, 어느 모형이 맞는지 판단한다 (Section 6.3, Section 8.2). Table 12 의 KS 거리는 공항에는 역법칙, 영화에는 정규분포가 가장 가깝다고 말한다.

5.5 KS 거리 (Kolmogorov–Smirnov Distance) 란

질문

what is KS distance?

고치는 문제. 모형 네 개를 그림으로 비교하면 그림이 여러 장 필요하고, 어느 모형이 “더” 가까운지 말하기 어렵다. 두 분포의 차이를 **숫자 하나로** 요약하고 싶다.

정의. 두 분포의 누적분포함수 (CDF) 를 겹쳐 그렸을 때, 두 곡선 사이 세로 간격 가운데 가장 큰 값이다.

$$D = \max_x |F_{\text{data}}(x) - F_{\text{model}}(x)| \quad (F(x) = “x \text{ 이하인 비율}”)$$

- F 는 0 과 1 사이이므로 D 도 0 과 1 사이이다.
- $D = 0$ 이면 두 분포가 같고, 1 에 가까울수록 크게 다르다.
- 한 곳만 크게 어긋나도 D 가 커진다. “가장 나쁜 곳 하나” 를 재는 거리다.

예제: 공항 데이터와 균등분포 $[1, 915]$. 균등분포의 CDF 는 $F(x) = (x - 1)/914$ 인 직선이다. 데이터의 CDF 는 처음에 급하게 오른다. 간격이 가장 큰 곳은 노선 60 개다 (Figure 6, python 으로 계산, 2026/09/29).

$$F_{\text{data}}(60) = 0.922$$

실제 공항의 92.2% 가 노선 60 개 이하

$$F_{\text{model}}(60) = (60 - 1)/914 = 0.065$$

균등 모형은 6.5% 라고 말한다

$$D = 0.922 - 0.065 = 0.857$$

가장 큰 간격




Figure 6: 공항 데이터의 CDF(파란 실선) 와 균등분포 $[1, 915]$ 의 CDF(주황 점선). 빨간 화살표가 두 곡선의 가장 큰 세로 간격 $D = 0.857$ 이다 (노선 60 개).

숫자 하나로 비교. 공항 데이터에서 네 모형의 D 는 멱법칙 0.209, 지수 0.397, 균등 0.856, 정규 0.365 이다 (Table 12). 가장 작은 멱법칙이 가장 가깝다.

주의 1: 코드는 공식이 아니라 표본과 비교한다. HW2 코드는 `scipy.stats.ks_2samp(data, sample)`, 곧 두 표본 (Two-Sample) KS 를 쓴다. 모형의 공식 CDF 대신 모형에서 뽑은 표본 (Section 6.2) 의 CDF 와 비교한다. 그래서 씨드를 바꾸면 D 가 조금 달라진다. 균등분포는 공식 CDF 로 0.857, 표본으로 0.856 이다.

주의 2: D 는 “얼마나” 만 말한다. 어디가 왜 다른지는 말하지 않는다. 멱법칙은 D 가 가장 작지만, 노선 100 개 이상의 꼬리에서 어긋난다 (Section 6.3). 이것은 그림을 봐야 보인다. 그래서 D 는 그림과 함께 쓴다.

질문

D. Two-sample Kolmogorov–Smirnov distance: the largest vertical gap between the two CDFs (0 = identical). explain more

두 표본 (Two-Sample) 이란. One-sample KS 는 데이터를 모형의 공식 CDF 와 비교한다. Two-sample KS 는 데이터를 다른 표본과 비교한다. 이 과제는 모형에서 뽑은 가짜 공항 3409 곳이 그 다른 표본이다 (`scipy.stats.ks_2samp`). 두 CDF 는 모두 표본 하나로 만든 계단 모양의 경험적 CDF(Empirical CDF) 다.

작은 예: $A = \{1, 2, 3\}$, $B = \{2, 3, 4\}$. 값마다 두 CDF 의 높이를 잰다 (Table 16). 가장 큰 간격이 $1/3$ 이므로 $D = 0.333$ 이다. $D = 1$ 은 한쪽이 모두 끝난 뒤에 다른 쪽이 시작하는, 전혀 겹치지 않는 경우다.

Table 16: 두 작은 표본의 경험적 CDF 와 세로 간격.

x	A 의 CDF	B 의 CDF	간격
1	$1/3$	0	$1/3$
2	$2/3$	$1/3$	$1/3$
3	1	$2/3$	$1/3$
4	1	1	0

공항 데이터에서 D 가 생긴 곳. `ks_2samp` 의 `statistic_location` 으로 간격이 가장 큰 x 를 찾았다 (Table 17, python 으로 계산, 2026/09/30).

Table 17: 공항 데이터와 네 모형 표본 사이 KS 간격이 가장 큰 곳.

모형	D	위치 x	데이터 CDF	모형 CDF	이유
멱법칙	0.209	1	0.209	0.000	정수 데이터 대 연속 모형 (아래)
지수	0.397	6	0.648	0.251	작은 공항이 너무 적다고 예측
균등	0.856	60	0.922	0.065	대부분의 공항이 작다는 것을 무시
정규	0.365	≈ 1	0.000	0.365	모형 표본의 36% 가 음수

멱법칙의 D 는 꼬리가 아니라 $x = 1$ 에서 나온다. 실제 공항의 20.9% 는 노선이 정확히 1 개다. 모형은 연속분포라 1.0, 1.3, 2.7 같은 값을 내고, “1 이하” 인 표본은 거의 없다. 정수 데이터를 연속 모형과 비교해서 생긴 간격이다. 꼬리의 어긋남 (노선 100 개 이상) 은 그림에서는 크지만 해당 공항이 적어 D 에는 작게 반영된다. 주의 2 가 말한 “ D 는 어디가 왜 다른지 말하지 않는다” 의 실제 예다. 균등분포의 위치가 Figure 6 의 60 과 다른 것은 거기서는 공식 CDF, 여기서는 표본과 비교해서다. D 는 둘 다 0.857 이다.

왜 p 값이 아니라 D 인가. `ks_2samp` 는 검정의 p 값 (p-value) 도 준다. 공항 데이터에서는 네 모형 모두 약 10^{-65} 이하다. 표본이 수천 개면 아주 작은 차이도 “통계적으로 다르다” 고 나온다. 그래서 “어느 모형이 더 가까운가” 는 D 의 크기로 비교한다.

질문

they why model sample data does have 0.97? does it have to be 0 or 1?

정수 데이터 대 연속 모형. 모형 표본은 연속분포에서 뽑은 실수다. 정규분포는 소수도 음수도 내고 (공항 표본의 36% 가 음수), 멱법칙 표본도 1.08, 2.18 처럼 소수다. 실제 노선 수는 1 이상의 정수다. 그래서 D 의 일부는 모양이 아니라 이 차이에서만 생긴다. 공항 정규분포의 간격이 “ $x = 0.98$ ” 에서 가장 큰 것도 그래서다. 데이터 CDF 는 1 바로 앞까지 0 이고, 모형 표본의 36.5% 는 이미 1 아래에 있다. 0.98 은 1 아래 표본 값 가운데 가장 큰 값일 뿐이다.

확인하려고 모형 표본을 데이터와 같은 단위로 반올림해 D 를 다시 계산했다 (공항은 정수로, 영화는 평점처럼 0.1 단위로; Table 18, python, 씨드 20701313, 2026/09/30).

Table 18: 모형 표본을 데이터의 단위로 반올림하기 전후의 KS 거리 D .

데이터	역법칙	지수	균등	정규
공항	연속 표본	0.209	0.397	0.856
	정수로 반올림	0.056	0.381	0.855
영화	연속 표본	0.490	0.481	0.380
	0.1 로 반올림	0.486	0.477	0.375

- 공항 역법칙의 D 는 거의 사라진다. 반올림하면 1–1.5 사이 표본 (약 $1 - 1.5^{-0.612} \approx 22\%$) 이 모두 1 이 되어 데이터의 20.9% 에 가까워진다. $D = 0.209$ 는 대부분 “정수 대 연속” 의 차이였다.
- 나머지는 거의 그대로다. 반올림 문제가 아니라 모양이 틀린 것이라서다 (정규의 음수, 균등의 평평함, 지수의 빠른 꼬리).
- 영화 정규분포는 더 가까워진다 ($0.048 \rightarrow 0.026$).
- 결론은 같고 오히려 더 강해진다. 과제가 연속 분포를 적합하라고 했으므로 보고서의 표는 연속 표본 값을 쓴다.

6 HW2 문제 1: 공항 노선 수 데이터

강의 노트: §10.4 공항 노선 수, §10.3 네 모형을 비교하는 방법. KS 거리는 8 장 §8.8, Q-Q 플롯은 5 장 §5.5.

문제 1(a)

What is the α if the distribution is power law?

Equation (2) 를 공항별 노선 수 데이터 (01_airport_routes.csv) 에 적용한다. 보고서의 답은 다음과 같다.

$n = 3409$	공항 수
$x_{\min} = 1$	데이터의 최솟값 (노선 1 개)
$\hat{\alpha} = 1.612$	Equation (2) 의 결과

질문

그러면 현재 항공 데이터를 가지고 이 formular 에 대입해서 alpha 를 구하는 건가?

대입 과정. 그렇다. Section 3 의 {1, 2, 4} 예제와 같은 계산을 공항 3409 개에 한다 (python 으로 다시 계산, 2026/09/29). HW2 코드 (hw2/code/common.py 의 fit_power_law) 도 같은 식이다.

먼저 공항마다 “최솟값의 몇 배인가” 에 로그를 씌운다. 세 공항만 보이면 다음과 같다.

AAX : $\ln(1/1) = 0$	노선 1 개 (이런 공항이 713 곳)
MFE : $\ln(6/1) = 1.792$	노선 6 개 (McAllen)
ATL : $\ln(915/1) = 6.819$	노선 915 개 (최대)

3409 개를 모두 더하고 식에 넣는다.

$$\begin{aligned} S &= \sum_{i=1}^{3409} \ln(x_i/1) = 5569.43 && \text{로그의 합} \\ S/n &= 5569.43/3409 = 1.634 && \text{로그의 평균 (보통 공항은 최솟값의 } e^{1.634} \approx 5 \text{ 배)} \\ \hat{\alpha} &= 1 + 3409/5569.43 = 1.612 && \text{Equation (2)} \end{aligned}$$

Table 19 에 단계를 한데 모았다.

Table 19: 공항 데이터로 $\hat{\alpha}$ 를 구하는 단계 (python 으로 계산, 2026/09/29).

단계	값	뜻
n	3409	공항 수
$x_{\min}$	1	데이터 최솟값 (노선 1 개)
$S = \sum_i \ln(x_i/x_{\min})$	5569.43	공항마다 “최솟값의 몇 배인가” 에 로그 (Log) 를 씌워 모두 더한 값
S/n	1.634	그 로그 값의 평균
$\hat{\alpha} = 1 + n/S$	$1 + 3409/5569.43 = 1.612$	추정값

주의. $x_{\min} = 1$ 로 둔 것은 **모든 공항이** 역법칙을 따른다는 가정이다. 실제 데이터는 대개 어떤 값 이상의 꼬리에서만 역법칙을 따르고, $x_{\min}$ 을 바꾸면 $\hat{\alpha}$ 도 바뀐다. 이 가정이 맞는지는 공식이 알려 주지 않는다. 모형에서 표본을 생성해 겹쳐 그려야 알 수 있다 (Section 6.3).

6.1 $\hat{\alpha} = 1.612$ 가 뜻하는 것

$1 < \hat{\alpha} < 2$ 이다. Section 2.5 의 조건에 따라 확률분포는 되지만, 이 모형에서는 평균도 분산도 유한하지 않다. 그래서 모형에서 뽑은 표본은 노선이 10^4 에서 10^5 개인 공항까지 만들어 낸다. 실제 데이터는 최대 915 에서 멈춘다.

6.2 모형에서 표본 뽑기: 역변환 샘플링 (Inverse Transform Sampling)

질문

Airport data vs. samples from the fitted power law model.: how can we get samples from the fitted power law model?

고치는 문제. 과제는 추정한 모형에서 데이터와 같은 개수 ($n = 3409$) 의 난수 표본 (Random Sample) 을 뽑아 실제 데이터와 겹쳐 그리라고 한다. 지수, 균등, 정규분포는 numpy 에 표본 함수가 있지만 역법칙 (Power Law) 표본 함수는 없다. 그래서 직접 만든다.

아이디어. 컴퓨터가 기본으로 주는 난수는 0 과 1 사이의 균등 난수 (Uniform Random Number) u 하나뿐이다. 이것을 원하는 분포의 값으로 바꾸는 다리가 **누적분포함수** (CDF, Cumulative Distribution Function) $F(x) = P(X \leq x)$ 다. F 는 값 x 를 “ x 이하인 비율”(0 에서 1 사이) 로 보낸다. 거꾸로 비율 u 를 넣어 x 를 푸는 함수 $F^{-1}(u)$ 를 쓰면, u 가 균등하게 퍼져 있을 때 나온 x 들은 정확히 F 를 따른다. “ $u = 0.9$ ” 는 “아래에서 90% 자리의 값” 을 달라는 뜻이기 때문이다.

유도. 멱법칙의 꼬리 확률은 $P(X \geq x) = (x/x_{\min})^{-(\alpha-1)}$ 이다 (Section 1.1).

$$\begin{aligned}
 u = F(x) &= 1 - \left(\frac{x}{x_{\min}} \right)^{-(\alpha-1)} && \text{CDF} = 1 - \text{꼬리 확률} \\
 1 - u &= \left(\frac{x}{x_{\min}} \right)^{-(\alpha-1)} && x \text{ 가 있는 항을 한쪽으로} \\
 (1 - u)^{-1/(\alpha-1)} &= \frac{x}{x_{\min}} && \text{양변을 } -1/(\alpha-1) \text{ 제곱} \\
 x &= x_{\min} (1 - u)^{-1/(\alpha-1)} && x_{\min} \text{ 을 곱했다}
 \end{aligned}$$

HW2 코드 (hw2/code/common.py 의 sample_models) 가 이 줄을 그대로 쓴다.

```
pl_sample = x_min * (1.0 - rng.random(n)) ** (-1.0 / (alpha - 1.0))
```

`rng.random` 은 $[0, 1)$ 에서 뽑으므로 $u = 0$ 은 나와도 $u = 1$ 은 나오지 않는다. 그래서 $1 - u$ 는 0 이 되지 않고, 0 의 음수 제곱 (무한대) 이 생기지 않는다. `rng` 는 씨드 (Seed) 20701313(소유자의 학번) 으로 고정해서 그림을 다시 만들 수 있게 했다.

예제: 공항 데이터, $\hat{\alpha} = 1.612$, $x_{\min} = 1$. 지수는 $-1/(\hat{\alpha} - 1) = -1/0.612 = -1.634$ 다. u 몇 개를 넣어 보고, 실제 데이터의 같은 위치 값과 나란히 놓는다 (Table 20, python 으로 계산, 2026/09/29).

Table 20: 역변환 샘플링으로 얻는 멱법칙 표본 값과 실제 공항 데이터의 같은 위치 값.

u 모형 $x = (1 - u)^{-1.634}$	실제 데이터의 같은 위치
0.5 (중앙값)	3.1
0.9	43
0.99	1851
	283

90% 자리까지는 모형과 데이터가 거의 같다. 99% 자리에서 모형은 1851 을 내고 실제 데이터는 283 이다. 실제 최대는 915 인데 모형은 이보다 큰 값을 계속 만든다. Section 6.3 에서 본 “약 100 개 이상에서 어긋난다” 가 이 숫자로도 드러난다.

질문

so you use distribution formular to find data predicted?

예측이 아니라 가상의 데이터다. 분포 공식을 쓰는 것은 맞다. 다만 나오는 것은 공항마다의 예측값 (Predicted Value) 이 아니라 **가상의 데이터** (Synthetic Data) 다. 흐름은 다음과 같다.

1. 실제 데이터로 모수를 추정한다: $\hat{\alpha} = 1.612$ (Table 19).
2. $\hat{\alpha}$ 를 역변환 공식 $x = x_{\min}(1 - u)^{-1/(\hat{\alpha}-1)}$ 에 넣는다.
3. 균등 난수 u 를 3409 개 뽑아 넣는다. 가짜 공항 3409 곳의 노선 수가 나온다.
4. 가짜 데이터와 진짜 데이터의 **분포 모양**을 겹쳐 그려 비교한다.

예측과 다른 점.

- 가짜 값 하나하나의 특정 공향과 짝이 없다. “ATL 의 노선 수를 예측한 값” 이 아니다.
- 이 표본이 답하는 질문은 “세상이 정말 이 모형대로라면, 공항 3409 곳의 노선 수는 어떻게 퍼져 있을까?” 다.
- 그래서 점 하나하나가 아니라 전체 모양을 비교한다. 중앙값 (Median) 이 비슷한가, 90% 자리 값이 비슷한가, 꼬리 (Tail) 가 어디까지 가는가. QQ plot 은 이 위치들을 하나씩 짝지어 그린 그림이다.
- 난수라서 씨드 (Seed) 를 바꾸면 값은 달라진다. 그래도 모양은 거의 같다.

Table 20 에서 50%, 90% 자리는 맞고 99% 자리는 크게 어긋났다. 모양이 맞는 구간과 어긋나는 구간이 모형을 판단하는 근거다. 첫 쪽 핵심 2 (가정은 시각적으로 검증한다) 가 이것이다.

나머지 세 모형. numpy 함수를 그대로 쓴다. 지수분포 함수는 λ 가 아니라 평균 $1/\lambda$ (척도 (Scale)) 를 받으니 주의한다.

```
rng.exponential(1.0 / lam, n) # exponential: scale = 1 / lambda
rng.uniform(a, b, n) # uniform on [a, b]
rng.normal(mu, sigma, n) # normal
```

6.3 적합이 맞는 범위

- 노선 1 개에서 약 60 개까지: 여집합 CDF 가 데이터와 겹치고, QQ 점이 $y = x$ 위에 놓인다.
- 약 100 개 이상: 데이터는 아래로 휘며 끊기고 (Cutoff), 모형은 직선으로 계속 간다.
- KS 거리 (Kolmogorov–Smirnov Distance) $D = 0.209$ 로 네 모형 (먹법칙, 지수, 균등, 정규) 중 가장 작다.




Figure 7: 공항 노선 수에 멱법칙 ($\hat{\alpha} = 1.612$, $x_{\min} = 1$) 을 적합한 결과 (code/p1_airport_f_powerlaw_plot.py 가 생성). $D = 0.209$.

7 지수분포란

강의 노트: 4 장 §4.3 지수분포 (deck 6 slide 15–18). CDF 의 정의는 2 장 §2.4.

질문

p1-b what is exponential distribution? why we need lambda? and what it is? why important?

지수분포 (Exponential Distribution) 는 **다음 사건까지 기다리는 시간**을 나타내는 분포다. 예: 다음 손님이 올 때까지의 시간, 다음 고장까지의 시간. 작은 값이 가장 흔하고, 값이 커질수록 확률이 일정한 비율로 줄어든다.

확률밀도함수 (PDF) 와 여집합 CDF 는 다음과 같다.

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0, \lambda > 0 \quad (3)$$

$$P(X > x) = e^{-\lambda x} \quad (4)$$

Figure 8 는 λ 만 바꾼 세 곡선이다. 모두 $x = 0$ 에서 높이 λ 로 시작해 줄어든다.




Figure 8: 지수분포 PDF $f(x) = \lambda e^{-\lambda x}$. 파란 실선 $\lambda = 0.5$, 빨간 점선 $\lambda = 1$, 초록 일점쇄선 $\lambda = 2$. 모양은 셋 다 같고 눈금만 다르다. λ 가 클수록 0 근처에 몰리고 평균 $1/\lambda$ 가 작아진다.

7.1 PDF, CDF, 평균과 분산 한눈에

질문

update this in note. I want to understand exponential distribution

PDF: 곡선의 높이. x 가 음수인 곳까지 포함해 쓰면 다음과 같다.

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

- λ : 비율 (Rate) 모수. 단위 시간당 사건이 평균 몇 번 일어나는가.
- $e \approx 2.718$: 오일러 수 (Euler's Number).
- x : 연속 변수. 보통 시간이나 거리 (“다음 사건까지 얼마나”).

$x < 0$ 에서 0 인 것은 기다리는 시간이 음수일 수 없기 때문이다.

CDF: 곡선 아래 넓이. CDF $F(x) = P(X \leq x)$ 는 “ x 안에 사건이 일어날 확률” 이고, PDF 를 0 부터 x 까지 적분한 넓이다.

$$\begin{aligned} F(x) &= \int_0^x \lambda e^{-\lambda t} dt \\ &= \left[-e^{-\lambda t} \right]_0^x \\ &= -e^{-\lambda x} - (-e^0) \\ &= 1 - e^{-\lambda x} \end{aligned}$$

PDF 의 넓이 ($x \geq 0$)

$$\frac{d}{dt}(-e^{-\lambda t}) = \lambda e^{-\lambda t}$$

위 끝 빼기 아래 끝

$$e^0 = 1$$

$x < 0$ 이면 $F(x) = 0$ 이다. 꼬리 확률은 $P(X > x) = 1 - F(x) = e^{-\lambda x}$ 로 Equation (4) 와 같다. Figure 9 는 $\lambda = 1.5$ 일 때 두 함수다. PDF 는 $x = 0$ 에서 $\lambda = 1.5$ 로 가장 높고 0 으로 줄어들며, CDF 는 0 에서 시작해 1 로 다가간다. PDF 아래 색칠한 넓이 ($0 \leq x \leq 1$) 가 CDF 의 $x = 1$ 높이 $1 - e^{-1.5} = 0.777$ 과 같다.




Figure 9: $\lambda = 1.5$ 인 지수분포. 왼쪽: PDF $1.5e^{-1.5x}$ (파란 선) 와 $0 \leq x \leq 1$ 의 넓이 (파란 면). 오른쪽: CDF $1 - e^{-1.5x}$ (빨간 선). 회색 점선은 높이 1 이다. 왼쪽 면의 넓이와 오른쪽 점 $F(1)$ 의 높이가 둘 다 0.777 이다.

평균, 분산, 표준편차. 결과부터 적는다.

$$E[X] = \mu = 1/\lambda$$

평균 (기댓값)

$$\text{Var}[X] = \sigma^2 = 1/\lambda^2$$

분산

$$\sigma = 1/\lambda$$

표준편차: 평균과 같다

유도는 부분적분 (Integration by Parts) $\int u dv = uv - \int v du$ 를 쓴다. $u = x$, $dv = \lambda e^{-\lambda x} dx$ 로 두면 $v = -e^{-\lambda x}$ 다.

$$\begin{aligned} E[X] &= \int_0^\infty x \lambda e^{-\lambda x} dx \\ &= \left[-xe^{-\lambda x} \right]_0^\infty + \int_0^\infty e^{-\lambda x} dx \\ &= 0 + \frac{1}{\lambda} \end{aligned}$$

평균의 정의

부분적분

$$xe^{-\lambda x} \rightarrow 0, \int_0^\infty e^{-\lambda x} dx = 1/\lambda$$

같은 방법 ($u = x^2$) 으로 $E[X^2] = \frac{2}{\lambda} E[X] = \frac{2}{\lambda^2}$ 이다. 그래서

$$\text{Var}[X] = E[X^2] - (E[X])^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2} \quad (\text{Section 2.5 과 같은 공식})$$

“평균 = 표준편차” 로 데이터를 점검한다. 지수분포라면 표준편차 ÷ 평균이 정확히 1 이다. 이 비율을 변동 계수 (Coefficient of Variation) 라 한다. 두 데이터에서 계산하면 (Table 12 의 값) 둘 다 1 과 멀다.

$$\text{공항: } 53.506/19.845 = 2.70$$

지수분포보다 훨씬 넓게 퍼진다 (꼬리가 두껍다)

$$\text{영화: } 0.893/6.227 = 0.14$$

지수분포보다 훨씬 좁게 몰려 있다

모수 $\hat{\lambda}$ 를 구하기 전에, 숫자 둘만으로 지수분포가 맞지 않을 것을 미리 알 수 있다.

예제: 버스 기다리기. 버스가 평균 10 분에 한 대 온다고 하자. 도착 간격이 지수분포라면 $\lambda = 1/10 = 0.1$ (분당) 이다.

$$P(X \leq 5) = 1 - e^{-0.5} = 0.393$$

5 분 안에 옴 (CDF)

$$P(X > 20) = e^{-2} = 0.135$$

20 분 넘게 기다림 (꼬리)

$$P(X > 20 | X > 10) = e^{-1} = 0.368$$

10 분 기다린 뒤 10 분 더

셋째 줄은 처음부터 10 분 넘게 기다릴 확률 $P(X > 10) = e^{-1}$ 과 같다. 이미 기다린 시간이 남은 시간에 영향을 주지 않는다. 아래 “왜 중요한가” 의 무기역성 (Memoryless Property) 이 이것이다.

7.2 λ 는 무엇인가

λ 는 **비율** (Rate) 이다. 단위 시간당 사건이 평균 몇 번 일어나는지를 뜻한다.

$$E[X] = 1/\lambda$$

평균 대기 시간

$$SD[X] = 1/\lambda$$

표준편차도 평균과 같다

예: 손님이 분당 평균 $\lambda = 0.5$ 명 온다면, 평균 대기 시간은 $1/0.5 = 2$ 분이다.

7.3 왜 λ 가 필요한가

지수분포의 **모양**은 하나로 정해져 있다 (0 에서 가장 높고, 오른쪽으로 줄어드는 곡선). 정해지지 않은 것은 **눈금** (Scale) 뿐이다. 곡선이 몇 분 만에 줄어드는지, 몇 시간에 걸쳐 줄어드는지를 λ 하나가 정한다. 그래서 λ 없이는 어떤 확률도 숫자로 계산할 수 없다.

예: $\lambda = 0.5$ 일 때 4 분 넘게 기다릴 확률은 Equation (4) 로

$$P(X > 4) = e^{-0.5 \cdot 4} = e^{-2} = 0.135 \quad (\text{약 } 13.5\%)$$

7.4 데이터에서 λ 추정하기

최대우도추정 (MLE) 은 표본 평균의 역수다.

$$\hat{\lambda} = \frac{1}{\bar{x}} \quad (\text{평균이 } 1/\lambda \text{ 이므로 거꾸로 푼다})$$

7.5 왜 중요한가

- **무기역성** (Memoryless Property): 이미 s 만큼 기다렸어도, 앞으로 t 더 기다릴 확률은 처음과 같다. $P(X > s + t | X > s) = e^{-\lambda t} = P(X > t)$. 연속 분포 중 이 성질을 가진 것은 지수분포뿐이다.

- 포아송 과정 (Poisson Process) 과 짝이다. 일정 시간 동안 사건 수가 포아송분포를 따르면, 사건 사이 간격은 지수분포를 따른다.
- 꼬리 비교의 기준선이다. 지수분포의 꼬리는 $e^{-\lambda x}$ 로 빨리 줄어든다 (가벼운 꼬리, Light Tail). 멱법칙의 $x^{-\alpha}$ 는 훨씬 느리게 줄어든다. 로그-로그 축에서 직선인가 휘는가 (Figure 4) 로 둘을 가른다.

8 HW2 문제 1: 영화 평점 데이터

강의 노트: §10.5 영화 평점, §10.2 모수 추정 (지수분포 MLE 예제).

문제 1(b)

What is the λ if the distribution is exponential?

영화 평균 평점 (01_movie_votes.csv, $n = 4392$) 에 $\hat{\lambda} = 1/\bar{x}$ 를 적용한다. 보고서의 답은 다음과 같다.

$$\bar{x} = 6.227$$

표본 평균

$$\hat{\lambda} = 1/6.227 = 0.1606$$

MLE

8.1 결과: 지수분포는 맞지 않는다

- 지수분포는 0 에서 가장 높다. 데이터는 약 6.3 에서 봉우리가 하나인 거의 대칭 모양이다.
- 모형 표본의 4% 가 20 을 넘는다. 평점으로 가능하지 않은 값이다.
- KS 거리 $D = 0.481$. 정규분포는 $D = 0.048$ 로 가장 잘 맞는다.

Table 21: 두 데이터에서 추정한 $\hat{\lambda}$ (보고서 값)

데이터	$\bar{x}$	$\hat{\lambda} = 1/\bar{x}$	KS 거리 D
공항 노선 수	19.845	0.0504	0.397
영화 평점	6.227	0.1606	0.481




Figure 10: 영화 평점에 지수분포 ($\hat{\lambda} = 0.1606$) 를 적합한 결과 (code/p1_movie_g_exponential_plot.py 가 생성). $D = 0.481$.

8.2 왜 공항은 CCDF, 영화는 PDF 로 그렸나

질문

and why airport has ccdf but movie has pdf? only?

먼저 사실 확인. 이 질문을 받았을 때 모형 비교 그림은 두 데이터 모두 왼쪽 패널 하나 + 오른쪽 QQ plot 하나였고, 공항은 CCDF, 영화는 PDF 를 왼쪽에 두었다. 과제는 PDF, CDF, QQ plot 중 하나면 된다고 했으니, 데이터마다 **모형 차이가 가장 잘 보이는** 그림을 고른 것이다. 지금 공항 그림은 PDF, CDF, CCDF 를 모두 보통 축과 로그-로그 축으로 그린다 (Table 22, code/common.py). 아래 이유는 그 가운데 어느 패널이 판단에 가장 쓸모 있는지에 대한 것이다.

Table 22: code/common.py 가 그리는 패널.

그림	공항 노선 수	영화 평점
데이터만 (*_0_data)	PDF, PMF, CDF, CCDF 를 보통 축 (0-200) 과 로그-로그 축으로	PDF(히스토그램) + CDF
모형 비교 (*_1 ~ *_4)	PDF, CDF, CCDF 를 보통 축 (0-200) 과 로그-로그 축으로 + QQ plot(로그-로그)	PDF(히스토그램) + QQ plot

공항은 왜 CCDF 인가. 꼬리가 길어서 PDF 가 꼬리에서 무너진다.

- 값의 범위가 1 에서 915 까지도. 보통 축의 히스토그램은 왼쪽 막대 하나로 뭉친다.
- 로그 축으로 바뀌도 꼬리에는 공항이 거의 없다. 노선 100 개 이상인 공항은 166 곳이고, 그 118 가지 값 가운데 81 가지는 공항이 딱 1 곳이다 (python 으로 계산, 2026/09/29). 값마다 확률을 찍으면 꼬리가 같은 높이의 점들로 흩어져 모양을 읽을 수 없다.
- CCDF $P(X \geq x)$ 는 “ x 이상인 공항 전부” 를 세므로, 꼬리의 공항들이 서로를 받쳐 준다. 구간 (Bin) 을 정할 필요도 없다.
- 무엇보다 문제의 핵심 가설 (멱법칙인가) 을 곧바로 시험한다. 멱법칙이면 로그-로그 CCDF 가 기울기 $-(\alpha - 1)$ 의 직선이다 (Section 2.1.1). 직선인지 휘는지가 한눈에 보인다.

질문

and in figure why did you mark ccdf? other than cdf?

왜 CDF 가 아니라 CCDF 인가. 둘은 같은 정보다. $CCDF = 1 - CDF$ 이므로 하나를 알면 다른 하나가 정해진다. 차이는 **로그 축에서 무엇이 보이느냐**다.

- CDF 는 꼬리에서 1 에 붙는다. 로그 축에서 1 근처 값들은 모두 $\log 1 = 0$ 근처에 몰려 구별되지 않는다.
- CCDF 는 꼬리에서 0 으로 간다. 로그 축은 0.1, 0.01, 0.001 을 같은 간격으로 벌려 준다. 꼬리가 크게 보인다.

공항 데이터로 확인한다 (python 으로 계산, 2026/09/29).

노선100 : $CDF = 0.952$, $\log_{10} 0.952 = -0.021$; $CCDF \approx 0.048$, $\log_{10} 0.048 = -1.32$

노선400 : $CDF = 0.996$, $\log_{10} 0.996 = -0.002$; $CCDF \approx 0.004$, $\log_{10} 0.004 = -2.40$

CDF 로는 두 점의 높이 차이가 0.019 라 한 점처럼 보인다. CCDF 로는 1.08, 곧 열 배 넘게 벌어진다. 또 멱법칙의 CCDF $(x/x_{\min})^{-(\alpha-1)}$ 는 로그-로그 축에서 직선이지만, CDF $1 - (x/x_{\min})^{-(\alpha-1)}$ 는 직선이 아니다. 그래서 꼬리가 긴 데이터에서 멱법칙을 시험할 때는 CCDF 를 쓴다.

KS 거리 (Section 5.5) 는 어느 쪽으로 재도 같다. $|F_1 - F_2| = |(1 - F_1) - (1 - F_2)|$ 이기 때문이다. Figure 6 이 CDF 를 보통 축으로 그린 것은 간격을 눈으로 재기 쉬워서다.

질문

ccdf 좀 더 설명해주고 왜 log 를 취해서 하는 지도 설명해줘

CCDF 읽기. CCDF(Complementary CDF, 여누적분포함수) 는 “ x 개 이상인 비율” $P(X \geq x)$ 다. CDF 가 “ x 이하” 를 아래에서 세면, CCDF 는 “ x 이상” 을 위에서 센다. 항상 1 에서 시작해 오른쪽으로 갈수록 줄고, 마지막 값은 가장 큰 공항 하나의 몫 $1/3409 \approx 0.0003$ 이다.

질문

멱법칙 모형 ($x^{-0.612}$): 이건 어디에 있어?

멱법칙 모형의 CCDF 는 어디서 오나. 멱법칙의 꼬리 확률 $P(X \geq x) = (x/x_{\min})^{-(\alpha-1)}$ (Section 1.1) 에 공항의 추정값을 넣은 것이다.

$$\begin{aligned} P(X \geq x) &= \left(\frac{x}{x_{\min}} \right)^{-(\alpha-1)} && \text{멱법칙의 CCDF} \\ &= \left(\frac{x}{1} \right)^{-(1.612-1)} && x_{\min} = 1, \hat{\alpha} = 1.612 \text{ (Table 19)} \\ &= x^{-0.612} && \text{지수 정리} \end{aligned}$$

예: $x = 10$ 이면 $10^{-0.612} = 0.244$, 곧 “노선 10 개 이상인 공항이 24%” 라고 모형이 말한다.

Table 23: 공항 데이터의 CCDF 와 멱법칙 모형 $x^{-0.612}$ 의 CCDF (python 으로 계산, 2026/09/29).

x (노선 수)	“ x 개 이상” 공항	데이터 $P(X \geq x)$	모형 $x^{-0.612}$
1	3409 곳	1.0	1.0
10	959 곳	0.28	0.24
100	166 곳	0.049	0.060
500	5 곳	0.0015	0.022
915	1 곳 (ATL)	0.0003	0.015

노선 100 개까지는 데이터와 모형이 비슷하다. 500 개와 915 개에서는 모형이 10 배 넘게 크다. 모형 그림 (pia_1_powerlaw) 의 CCDF 패널에서 두 선이 벌어지는 곳이다.

왜 로그를 취하나. 세 가지 이유가 있다.

1. **범위가 넓다.** 가로축은 1 에서 915 까지 약 1000 배, 세로축은 1 에서 0.0003 까지 약 3000 배다. 보통 축에서는 0.05 아래의 꼬리 전체 (노선 100 개 이상) 가 바닥선에 붙고, 공항의 72%(노선 10 개 미만) 가 가로축 왼쪽 1% 폭에 몰린다. 로그 축은 1, 10, 100, 1000 과 1, 0.1, 0.01, 0.001 을 같은 간격으로 놓는다.
2. **멱법칙이 직선이 된다.** $\log P(X \geq x) = -(\alpha - 1) \log x$ 는 $\log x$ 의 일차식이므로 기울기 -0.612 의 직선이다 (Section 2.1.1). 눈은 “직선인가, 휘었는가” 를 곡선끼리의 비교보다 훨씬 잘 판단한다. 공항 데이터는 약 100 개까지 직선이다가 아래로 휘다. “멱법칙인데 상한이 있다” 는 결론이 이 모양에서 나온다.
3. **비율로 읽힌다.** 로그 축에서 세로 한 칸은 “10 배” 다. 두 선이 한 칸 벌어져 있으면 모형이 그 구간의 공항 수를 10 배 틀린다는 뜻이다. 보통 축에서는 0.0015 와 0.022 의 차이가 0.02 로 작아 보이지만, 실제로는 15 배 차이이다.

질문

then we can use cdf with log? ... why log log cdf is not a straight line?

세 가지 축 비교. 같은 공항 데이터와 멱법칙 표본을 세 가지 축으로 그렸다 (Figure 11). CDF 도 로그 축에 그릴 수 있다. 다만 어느 축에 로그를 씌우느냐가 중요하다.

- **CDF, 가로축만 로그:** 노선 1–100 개 구간이 펼쳐져 “몇% 가 x 개 이하인가” 를 읽기 좋다. 꼬리의 차이는 1.0 근처의 가는 틈으로만 보인다.
- **CDF, 로그-로그:** 노선 약 10 개 이후로 두 선이 맨 위 ($10^0 = 1$) 에 붙는다. 데이터가 915 에서 끝나고 모형이 10^5 까지 가는 차이가 거의 보이지 않는다.
- **CCDF, 로그-로그:** 약 100 개까지 같은 직선이고, 그 뒤로 데이터만 아래로 휜다. 꼬리의 차이가 가장 크게 보인다.




Figure 11: 공항 데이터 (파랑) 와 멱법칙 표본 (주황, $\hat{\alpha} = 1.612$) 을 세 가지 축으로 그린 것 (00_background/fig_cdf_axes.py 가 생성, 표본은 p1a_1_powerlaw 와 같다). 왼쪽: CDF, 가로축만 로그. 가운데: CDF, 로그-로그. 오른쪽: CCDF, 로그-로그.

질문

CDF: $P(X \leq x) = 1 - x^{-0.612} \dots$ wha tis it 1 - ? $P(X \leq x) = \text{integral from 0 to } x \text{ right?}$

CDF 는 PDF 의 적분이다: “1-” 는 어디서 오나. 그렇다. “0 부터 x 까지” 라고 해도 결과는 같다. 멱법칙의 PDF 는 $x \geq x_{\min}$ 에서만 정의되고 그 아래에서는 0 이므로, 실제로는 $x_{\min}$ 부터 적분한다.

$$P(X \leq x) = \int_0^x f(t) dt = \int_0^{x_{\min}} 0 dt + \int_{x_{\min}}^x f(t) dt = \int_{x_{\min}}^x f(t) dt$$

공항 모형 ($x_{\min} = 1$, $\alpha = 1.612$) 에서 PDF 는 $f(t) = (\alpha - 1) t^{-\alpha}$ 다 ($x_{\min} = 1$ 이라 앞의 $1/x_{\min}$ 이 사라진 꼴).

$$\begin{aligned} P(X \leq x) &= \int_1^x (\alpha - 1) t^{-\alpha} dt \\ &= (\alpha - 1) \left[\frac{t^{-\alpha+1}}{-\alpha+1} \right]_1^x \\ &= - \left[t^{-(\alpha-1)} \right]_1^x \\ &= -x^{-(\alpha-1)} - \left(-1^{-(\alpha-1)} \right) \\ &= 1 - x^{-(\alpha-1)} \\ &= 1 - x^{-0.612} \end{aligned}$$

PDF 를 1 부터 x 까지 적분

$$\text{거듭제곱 적분: } \int t^p dt = t^{p+1}/(p+1)$$

$$(\alpha - 1)/(-\alpha + 1) = -1$$

위 끝 x 를 넣은 값 빼기 아래 끝 1 을 넣은 값

1 의 몇 제곱이든 1

$$\alpha - 1 = 0.612$$

“1”은 아래 끝 $t = 1$ 을 넣었을 때 나온 $1^{-0.612} = 1$ 이다. $x_{\min}$ 이 1 이 아니면 $P(X \leq x) = 1 - (x/x_{\min})^{-(\alpha-1)}$ 이고, 아래 끝을 넣으면 $(x_{\min}/x_{\min})^{\dots} = 1$ 이라 앞의 1 은 그대로 남는다.

다른 길로 확인. “ x 이하”와 “ x 이상”을 합치면 전체 1 이다 (연속분포라 정확히 x 인 확률은 0). 그래서 $CDF = 1 - CCDF = 1 - x^{-0.612}$ 로 같다.

$$1 - 10^{-0.612} = 1 - 0.244 = 0.756 \quad (x = 10: \text{모형은 } 75.6\%, \text{ 실제 데이터는 } 73.6\%)$$

왜 로그-로그 CDF 는 직선이 아닌가. 로그 법칙은 곱과 거듭제곱은 풀어 주지만 빼기는 풀어 주지 않는다 (Table 9).

$$\begin{aligned} \log CCDF &= \log x^{-0.612} = -0.612 \log x & \log x \text{의 일차식: 직선} \\ \log CDF &= \log (1 - x^{-0.612}) & \text{“1-” 때문에 풀리지 않는다: 직선 아님} \end{aligned}$$

두 끝에서 다르게 움직인다 (Table 24). 왼쪽 끝 ($x \rightarrow 1$)에서는 $CDF \rightarrow 0$, $\log 0 = -\infty$ 라 절벽처럼 떨어진 다. 오른쪽 끝에서는 $CDF \rightarrow 1$, $\log 1 = 0$ 이라 평평해진다. Figure 11 가운데 패널의 “왼쪽 수직, 위쪽 수평”이 이것이다.

Table 24: 모형 $x^{-0.612}$ 에서 계산한 로그 CDF 와 로그 CCDF (python 으로 계산, 2026/09/29). 로그 CCDF 는 $\log_{10} x$ 가 1 늘 때마다 정확히 0.612 씩 준다.

x	$\log_{10} x$	CDF	$\log_{10} CDF$	$\log_{10} CCDF$
1.01	0.004	0.006	-2.22	-0.003
1.1	0.041	0.057	-1.25	-0.025
2	0.301	0.346	-0.46	-0.184
10	1	0.756	-0.12	-0.612
100	2	0.940	-0.027	-1.224
1000	3	0.985	-0.006	-1.836

질문

so it is better to use 1 - cdf because we can remove 1? and it is equal to $P(X > x)$?

$1 - CDF = P(X > x)$, 그리고 코드는 왜 $P(X \geq x)$ 인가. $1 - CDF = 1 - (1 - x^{-0.612}) = x^{-0.612}$ 로 “1”이 지워져 순수한 거듭제곱만 남는다. 그래서 로그-로그 축에서 직선이다. 이것이 CCDF 다. 다만 “더 좋다”는 목적에 따른다. 꼬리와 멱법칙 확인에는 CCDF, “몇%가 x 이하인가”를 읽을 때는 CDF 가 직접적이다.

연속분포에서는 $P(X > x) = P(X \geq x)$ 다. 공항 노선 수는 정수라서 다르다.

$$P(X \geq x) = P(X > x) + P(X = x)$$

- $x = 1$: $P(X > 1) = 0.79$, $P(X \geq 1) = 1.0$ (노선 1 개인 공항이 713 곳).
- $x = 915$ (최댓값): $P(X > 915) = 0$, $P(X \geq 915) = 1/3409 \approx 0.0003$.

코드의 ccdf 함수가 $\geq$ 를 쓰는 이유는 로그 축이다. $P(X > x)$ 는 최댓값에서 0 이 되고 $\log 0 = -\infty$ 라 마지막 점이 그림에서 사라진다. $P(X \geq x)$ 는 1 에서 시작해 $1/3409$ 로 끝나 모든 점이 찍힌다. 멱법칙 문헌 (Clauset et al. 2009) 도 CCDF 를 $P(X \geq x)$ 로 정의한다.

질문

and I would like to add why we need to use ccdf with log log scale updated.

정리: 왜 로그-로그 CCDF 인가. 이 절의 내용을 한곳에 모은다 (Table 25). 역법칙인지 판단하는 것이 문제 1 의 핵심 질문이고, 그 판단이 가능한 그림이 로그-로그 CCDF 하나뿐이다.

Table 25: 공항 데이터를 로그-로그 CCDF 로 그리는 이유. 각 줄은 다른 선택이 실패하는 지점이다.

이유	다른 선택에서 생기는 문제	로그-로그 CCDF 에서는
범위가 넓다	보통 축: 공항 72% 가 가로축 왼쪽 1% 에, 꼬리 전체가 세로 바닥에 붙는다	1, 10, 100, 1000 과 1, 0.1, 0.01, 0.001 이 같은 간격이다
역법칙이 직선이 된다	$CDF = 1 - x^{-0.612}$: “1-” 때문에 로그 가 풀리지 않아 휘다 (Table 24)	$CCDF = x^{-0.612}$, $\log CCDF = -0.612 \log x$: 기울기 $-(\alpha - 1)$ 의 직선
꼬리가 보인다	로그-로그 CDF: 꼬리가 1 에 붙어 0.952 와 0.996 이 한 점처럼 보인다	꼬리가 0 쪽으로 가서 0.048 과 0.004 가 한 칸 넘게 벌어진다
비율로 읽힌다	보통 축: 0.0015 와 0.022 의 차이가 0.02 로 작아 보인다	세로 한 칸 = 10 배: 15 배 차이가 그대로 보인다
구간이 필요 없다	PDF: 꼬리에 공항이 1 곳뿐인 값이 많아 점이 흩어진다	“ x 이상 전부” 를 세어 꼬리가 부드럽다
마지막 점까지 찍힌다	$P(X > x)$: 최댓값에서 0, $\log 0 = -\infty$	$P(X \geq x)$: 1/3409 로 끝난다

그래서 판단은 이렇게 한다. 로그-로그 CCDF 가 직선이면 역법칙이고, 기울기가 $-(\hat{\alpha} - 1)$ 이다. 공항 데이터는 약 100 개까지 기울기 -0.612 의 직선이다가 아래로 휘다 (Figure 11 오른쪽). 그래서 결론은 “상한이 있는 역법칙” 이다.

영화는 왜 PDF 인가. 범위가 좁고 값마다 데이터가 많아서 PDF 가 잘 선다.

- 평점은 1.9 에서 8.5 사이, 0.1 단위로 61 가지 값뿐이다. 값 하나에 영화가 최대 209 편 있다. 히스토그램 막대가 안정적이다.
- 네 모형을 가르는 것은 **모양**이다. 봉우리가 가운데 하나인가 (정규), 평평한가 (균등), 0 에서 가장 높은가 (지수), 왼쪽에 몰렸는가 (역법칙). PDF 는 이 모양을 그대로 보여 준다.
- 꼬리가 없으므로 CCDF 나 로그 축의 장점이 없다. 범위가 1 에서 10 안이라 로그 축은 거의 직선 축과 같다.

정리. 그림은 “어느 것이 옳다” 가 아니라 “어느 것에서 모형 차이가 보이냐” 로 고른다. 꼬리가 긴 데이터는 CCDF(로그-로그), 좁고 봉우리가 있는 데이터는 PDF 가 좋다. QQ plot 은 둘 다에 붙여 전체 위치를 점검한다.

8.3 그림 패널마다 답하는 질문

질문

and why we add box plot for what?

모형 비교 그림의 패널은 각각 다른 질문에 답한다 (Table 26). 영화 평점 모형 그림에 상자그림 (Box Plot) 을 넣은 것은 마지막 질문을 맡을 그림이 따로 없었기 때문이다.

Table 26: 그림 패널마다 답하는 질문.

패널	답하는 질문
PDF (히스토그램)	모양이 같은가? (봉우리 위치, 꼬리)
PMF (공항)	노선이 정확히 k 개인 공항은 몇 곳인가? (노선 수는 정수)
CDF	x 이하인 비율은? 가장 크게 어긋나는 곳은 어디이고 얼마인가? (D)
CCDF	x 이상인 비율은? 로그-로그 축에서 멱법칙은 직선이다.
QQ plot	순위 자리마다 값이 같은가? ($y = x$ 위면 같다)
상자그림 (영화)	“보통” 값과 퍼짐, 범위가 같은가? 불가능한 평점 (1–10 밖) 이 있는가?

상자그림 읽는 법. 굵은 선은 중앙값 (Median), 상자는 가운데 50% 가 있는 범위 (사분위수 25%–75%), 수염은 상자에서 사분위 범위 (IQR) 의 1.5 배까지다. 그 너머의 극단값은 그리지 않았다 (멱법칙 표본의 수천 같은 값이 축을 망치지 않게). 파선은 가능한 평점 1 과 10 이다.

영화 평점에서 보이는 것 (python, 씨드 20701313).

- 멱법칙: 중앙값 4.2(데이터 6.3), 표본의 24% 가 10 초과.
- 지수: 중앙값 4.4, 표본의 35% 가 1–10 밖 (1 미만 16%, 10 초과 19%).
- 균등: 범위 안이지만 상자가 데이터의 두 배 넘게 넓다 (3.6–6.9 대 5.7–6.8).
- 정규: 상자와 수염이 데이터와 거의 같다.

상자그림만으로는 모양 (봉우리가 하나인지, 꼬리가 어떤지) 을 알 수 없다. 그래서 PDF 나 QQ 를 대신하지 않고 보조 그림으로 둔다. 과제는 PDF, CDF, QQ 중 하나면 충분하다고 했으므로 필수는 아니다.

9 HW2 문제 2: 나이 필터 1–100 대 1–99

질문

could you update table to compare 1 to 100 and 1 to 99? with numbers to make sure I am right? and check how changes?

과제는 “pick the ones ranging from 1 to 99 years” 라고 한다. 처음 코드는 $1 \leq \text{나이} \leq 100$ 으로 걸렸고, 지금은 과제대로 $1 \leq \text{나이} \leq 99$ 다. 두 필터의 차이는 **정확히 100 세인 816 명** 하나뿐이다. 이 816 명은 첫째 자리 숫자로 1, 마지막 자리 숫자로 0 에 들어간다. 그래서 바뀌는 방식은 세 가지뿐이다.

1. 첫째 자리 1: 0.18% 에서 0% 가 된다. 숫자 1 은 전부 100 세였다 (10-19 세는 없다).
2. 마지막 자리 0: 10.64% 에서 10.48% 로 준다.
3. 나머지 숫자: 분모가 816 줄어 모든 비율이 조금씩 오른다.

$$453,905/453,089 \approx 1.0018 \quad (\text{예: 첫째 자리 5 는 } 29.98\% \text{ 에서 } 30.03\%)$$

Table 27: 나이와 요약 통계: 1-100 대 1-99 (2026 년 기준).

항목	1-100	1-99	변화
상한 초과로 제외	6,684 (1.45%)	7,500 (1.63%)	+816
남은 인원 n	453,905	453,089	-816
나이 범위	27-100	27-99	
나이 평균 / 중앙값	56.87 / 55	56.79 / 55	-0.08 / 0
첫째 자리 평균 / 중앙값 / 최빈값	5.22 / 5 / 5	5.22 / 5 / 5	+0.008
첫째 자리 σ / 분산	1.44 / 2.08	1.43 / 2.05	-0.01 / -0.03
첫째 자리 왜도 (Skewness)	+0.49	+0.53	+0.04
정규분포와 최대 차이 (숫자 4)	5.21%p	5.30%p	+0.09
마지막 자리 평균 / 중앙값 / 최빈값	4.55 / 5 / 7	4.55 / 5 / 7	+0.008
마지막 자리 σ / 분산	2.87 / 8.26	2.87 / 8.24	-0.02 (분산)
마지막 자리, 10% 에서 최대 차이	1.10%p	1.12%p	+0.02

Table 28: 숫자별 비율 (%): 1-100 대 1-99.

숫자	첫째 자리 1-100	첫째 자리 1-99	마지막 자리 1-100	마지막 자리 1-99
0			10.64	10.48
1	0.18	0.00	9.28	9.30
2	0.74	0.74	9.55	9.57
3	7.89	7.90	8.95	8.97
4	24.49	24.53	10.27	10.28
5	29.98	30.03	9.94	9.96
6	18.91	18.95	10.28	10.30
7	9.94	9.95	11.10	11.12
8	5.42	5.43	10.64	10.66
9	2.45	2.45	9.34	9.36

그 결과.

- 나이 평균은 가장 큰 값 (100) 이 빠져 56.87 에서 56.79 로 조금 내려간다.
- 첫째 자리는 아래쪽 끝의 1 이 사라져 σ 와 분산이 줄고, 왼쪽 꼬리가 짧아져 오른쪽 치우침 (왜도) 이 0.49 에서 0.53 으로 조금 커진다.
- 마지막 자리는 끝값 0 이 줄어 분산이 8.26 에서 8.24 로 줄고, 균등분포의 8.25 에 여전히 가깝다.
- **결론은 그대로다.** 첫째 자리는 거의 정규분포, 마지막 자리는 거의 균등분포다.